Doob's H Transform是什么

> TL; DR Doob's H Transform 是一种对路径分布进行倾斜时可以使用的信用分配技术，它将每条路径的 Weight-To-Go 转换为每个时刻/位置的速度场变化。

考虑一系列从某个初始分布 p_0 出发，被 Ito SDE

$$\mathrm{d}X_t = b(t, X_t)\mathrm{d}t + \sigma_t \mathrm{d}W_t$$

控制的粒子，设路径空间中的路径分布为 $\mathbb{P}_{old}(\omega)\mathrm{d}\omega$。现在希望使用路径的泛函 $W[\omega]$ 对路径进行加权，但是*不修改这些路径在 $t=0$ 时刻形成的初始分布 $p_0(x_0)$*。下面以 x_0 代表路径的起点，$\tilde{\omega} = (x_1, x_2, \cdots, x_N)$ 代表一条路径除起点之外的部分，$\omega = (x_0, x_1, x_2, \cdots, x_N)$ 代表整条路径。直接对每条路径乘以 $W[\omega]$ 进行加权必然导致初始分布变化，一个合理的方案是：取定某起点 x_0，先考察从 x_0 出发的路径，为其赋予正比于 $W[\omega]$ 的权重。为了实现这个方案，需要引入起点相关的配分函数 $Z(x_0)$：

$$\mathbb{P}_{new}(\omega)\mathrm{d}\omega = p_0(x_0)\mathrm{d}x_0 \frac{W[\omega]}{Z(x_0)} \mathbb{P}_{old}(\tilde{\omega}|X_0 = x_0)\mathrm{d}\tilde{\omega}$$

配分函数：

$$Z(x_0) = \int W[\omega]\mathbb{P}_{old}(\tilde{\omega}|X_0 = x_0)\mathrm{d}\tilde{\omega}$$

不难发现这个配分函数保持初始分布不变，只需在 $\mathbb{P}_{new}(\omega)$ 中积分掉 $\tilde{\omega}$：

$$\begin{aligned}\left(\int \mathbb{P}_{new}(\omega)\mathrm{d}\tilde{\omega}\right)\mathrm{d}x_0 &= p_0(x_0)\mathrm{d}x_0 \frac{1}{Z(x_0)} \int W[\omega]\mathbb{P}_{old}(\tilde{\omega}|X_0 = x_0)\mathrm{d}\tilde{\omega} \\ &= p_0(x_0)\mathrm{d}x_0\end{aligned}$$

我们计算新、旧路径的概率比，这个概率比中必然包含起点相关的 $Z(x_0)$：

$$\begin{aligned}\frac{\mathbb{P}_{new}(\omega)\mathrm{d}\omega}{\mathbb{P}_{old}(\omega)\mathrm{d}\omega} &= \frac{\mathbb{P}_{new}(\omega)\mathrm{d}\omega}{\mathbb{P}_{old}(\tilde{\omega}|X_0 = x_0)\mathrm{d}\tilde{\omega}\, p_0(x_0)\mathrm{d}x_0} \\ &= \frac{W[\omega]}{Z(x_0)}\end{aligned}$$

现在，我们要考虑能否通过新的 Ito SDE 实现这个概率比。我们只考虑一个非常简单的情况：权重 $W[\omega]$ 由一个可以即时结算的部分和一个终点权重组成，也就是：

$$W[\omega] = \exp\left(\alpha \int_0^T r(t, X_t)\mathrm{d}t\right) \cdot w(X_T)$$

定义 Weight-To-Go 为从 t 时刻，x 位置启动的粒子, 沿着旧 Ito SDE在未来能获得的期望权重：

$$h(t, x) = \mathbb{E}_{old}\left[\exp\left(\alpha \int_t^T r(s, X_s)\mathrm{d}s\right) \cdot w(X_T)|X_t = x\right]$$

不难发现之前引入的起点依赖的配分函数 $Z(x_0)$ 实际上是从 $(0, x_0)$ 启动的粒子在未来获得的平均权重，即 $h(0, x_0)$，因此，我们将路径比写为

$$\frac{\mathbb{P}_{new}(\omega)\mathrm{d}\omega}{\mathbb{P}_{old}(\omega)\mathrm{d}\omega} = \frac{\exp\left(\alpha \int_0^T r(t, X_t)\mathrm{d}t\right) \cdot w(X_T)}{h(0, x_0)}$$

这个权重可以视作对路径作用量的调整。根据"路径积分随机化"，每条路径的概率与其作用量相关：

$$\mathbb{P}(\omega|X_0 = x_0) \propto \exp(-S[\omega])$$

对于旧的 Ito SDE，作用量

$$S_{old}[\omega] = \int_0^T \frac{1}{2\sigma_t^2}\|\dot{x}_t - b(t,x_t)\|^2 \mathrm{d}t$$

重新加权之后路径的作用量显然是

$$S_{new}[\omega] = S_{old}[\omega] - \alpha\int_0^T r(t,x_t)\mathrm{d}t - \log w(x_T) + \log h(0,x_0)$$

由于 Ito SDE 的漂移和作用量中的二次方项有关，接下来应思考如何把多出来的这一部分合理地塞入二次方项。首先引入 $\Phi(t,X_t) = \log h(t,X_t)$，由 Ito 引理得到：

$$\mathrm{d}\Phi = \left(\partial_t\Phi + b\cdot\nabla\Phi + \frac{\sigma_t^2}{2}\Delta\Phi\right)\mathrm{d}t + \sigma_t\nabla\Phi\mathrm{d}W_t$$

为什么我们要算这个 $\mathrm{d}\Phi$ 呢？因为此时左侧积分直接得到

$$\Phi(T,X_T) - \Phi(0,X_0) = \log w(X_T) - \log h(0,X_0)$$

这是新旧作用量之差中的一部分。但是现在右侧的东西不像能用来修改作用量的样子，可以考虑进一步处理 $\mathrm{d}t$ 项的系数，这需要 Φ 满足的 PDE。要得到 Φ 满足的 PDE，需要先看 h 满足的 PDE。考虑类似于 HJB 方程推导时的技巧，让时间前行 $\mathrm{d}t$：

$$h(t,x) = \mathbb{E}_{old}\left[\exp\left(\alpha\int_t^{t+\mathrm{d}t} r(s,X_s)\mathrm{d}s\right)h(t+\mathrm{d}t, X_t+\mathrm{d}X_t)|X_t = x\right]$$

展开右侧，获得 h 满足的 PDE：

$$\partial_t h(t,x) + b\cdot\nabla h(t,x) + \frac{1}{2}\sigma_t^2\Delta h(t,x) = -\alpha r(t,x)h(t,x)$$

做变量替换 $h\to\Phi$ 即得到 Φ 满足的 PDE：

$$\partial_t\Phi(t,x) + b\cdot\nabla\Phi(t,x) + \frac{1}{2}\sigma_t^2\Delta\Phi(t,x) = -\alpha r(t,x) - \frac{\sigma_t^2}{2}\|\nabla\Phi(t,x)\|^2$$

回代到刚刚用 Ito 引理算出的 $\mathrm{d}\Phi$ 中，推出

$$\mathrm{d}\Phi = \nabla\Phi(t,X_t)(\mathrm{d}X_t - b\mathrm{d}t) - \alpha r\mathrm{d}t - \frac{\sigma_t^2}{2}\|\nabla\Phi\|^2\mathrm{d}t$$

从而，新旧作用量之差

$$S_{new}[\omega] - S_{old}[\omega] = -\int_0^T \nabla\Phi(\mathrm{d}X_t - b(t,X_t)\mathrm{d}t) + \frac{1}{2}\int_0^T \sigma_t^2\|\nabla\Phi\|^2\mathrm{d}t$$

我们发现这正好可以配方，得到：

$$S_{new}[\omega] = \int_0^T \frac{1}{2\sigma_t^2}\|\dot{x} - (b+\sigma_t^2\nabla\Phi)\|^2\mathrm{d}t$$

也就是说，这种路径重加权可以直接通过修改 SDE 的漂移实现：

$$b(t,x)\to b(t,x) + \sigma_t^2\nabla_x\log h(t,x)$$

这里的 $h(t,x)$ 是我们之前定义的 Weight-To-Go。

此外，我们说明 Doob's H Transform 恰好是一个特定 SOC 问题的解。考虑如下控制输入为 $u(t,x)$ 的系统：

$$\mathrm{d}X_t = [b(t,X_t) + u(t,X_t)]\mathrm{d}t + \sigma_t\mathrm{d}W_t,\ \ X_0\sim p_0$$

我们要求在付出尽可能小的控制能量的情况下获得最大奖励，因此奖励函数设置为

$$J = \mathbb{E}_{X_0 \sim p_0, X_t} \left[-\int_0^T \frac{\|u(t, X_t)\|^2}{2\sigma_t^2} \mathrm{d}t + \int_0^T \alpha r(t, X_t) \mathrm{d}t + \log w(X_T) \right]$$

使用标准的值方法求解这个 SOC 问题，定义最优控制律下的 Reward-To-Go：

$$V(t, x) = \sup_u \mathbb{E} \left[-\int_t^T \frac{\|u(s, X_s)\|^2}{2\sigma_s^2} \mathrm{d}s + \int_t^T \alpha r(s, X_s) \mathrm{d}s + \log w(X_T) | X_t = x \right]$$

利用动态规划中子问题的最优性知道：

$$V(t, x) = \sup_u \mathbb{E} \left[\int_t^{t+\mathrm{d}t} \left(\alpha r - \frac{\|u\|^2}{2\sigma_s^2} \right) \mathrm{d}s + V(t + \mathrm{d}t, X_{t+\mathrm{d}t}) | X_t = x \right]$$

使用 Ito 引理展开，得到：

$$\begin{aligned} 0 = \partial_t V(t, x) + b(t, x) \cdot \nabla V(t, x) + \alpha r(t, x) + \frac{\sigma_t^2}{2} \Delta V(t, x) \\ + \sup_u \left[u(t, x) \cdot \nabla V(t, x) - \frac{\|u(t, x)\|^2}{2\sigma_t^2} \right] \end{aligned}$$

完成其中的 $\sup$ 得到最优控制律

$$u^\star(t, x) = \sigma_t^2 \nabla V(t, x)$$

把这个结果送回 HJB 方程得到：

$$\partial_t V + b \cdot \nabla V + \frac{\sigma_t^2}{2} \Delta V + \frac{\sigma_t^2}{2} \|\nabla V\|^2 + \alpha r = 0$$

注意：这里 V 满足的 PDE 与之前 Φ 满足的 PDE 完全一致，并且它们的终端条件相同。因此我们可以认为这里的 V 就是 Doob's H Transform 中的 Φ，也即最优控制律是

$$u^\star(t, x) = \sigma_t^2 \nabla \log h(t, x)$$