

» 再谈随机过程

之前我们似乎一直模糊地“随机过程”下一个明确的定义，现在我们说：一个随机过程是在同一个样本空间 (Ω, \mathcal{F}, P) 上的以 ω 为指称的随机变量族 $\{X_t, t \in T\}$ 。对于 $t \in T$ ， X_t 可取值的范围被称作“状态空间”。显然，随机过程可以看作一个 $T \times \Omega \rightarrow S$ 的映射。

在 $t \in T$ 固定时， $X_t(\cdot, \cdot)$ 为 (Ω, \mathcal{F}, P) 上的随机变量，而当 $\omega \in \Omega$ 固定时， $X_t(\cdot, \omega)$ 则是 $T \rightarrow S$ 的函数。

接下来用一个经典的例子所谓“事件代数”。考虑一个掷硬币的过程，它的样本空间当然为 $\Omega = \{\text{H, T}\}^3$ 。对于每一个样本空间，我们可以定义不同的6-代数。

众所周知，不同的6-代数上面跟着不同的事件。而在不同的时间上，我们了解到用当前已知的信息推断不同6-代数中的事件是否发生。

具体的例子：抛硬币。假设我们抛掷三次硬币。

在事件时，我们从事件 $\Omega_0 = \{\text{H, T}\}^3$ 。

在事件时，可得到 $\mathcal{F}_1 = \{\text{H, T, } (\text{H}, \cdot), (\text{T}, \cdot)\}$

同理有 $\mathcal{F}_2 = \{\text{H, T, } (\text{H}, \cdot), (\text{T}, \cdot), (\cdot, \text{H}), (\cdot, \text{T})\}$ 。

这一系列的6-代数有性质：有 $t_1 < t_2$ ，总有 $\mathcal{F}_{t_1} \subset \mathcal{F}_{t_2}$ 。定义最初的“大”6-代数为 $\mathcal{F} := \mathcal{F}_\infty := \bigcap_{t=1}^{\infty} \mathcal{F}_t$ 的补集6-代数。

跟着前面的6-代数前面的反“细”，包含的信息也更多。

这恰恰说明更多的6-代数。

\mathcal{F}_t 被称为“6-代数流”，“事件域流”或“流域”。在研究随机过程时，我们通常研究一个带有流域的样本空间 $(\Omega, \mathcal{F}, \{\mathcal{F}_t\}, P)$ 。

» 对布朗运动的进一步研究。

下面继续研究布朗运动的性质。首先研究运动的停滞性。 $K(s, x, t, dy) = P(X(t) \in dy | X(s) = x)$

那么，根据之前对于布朗运动的定义，我们显然有：

$$\lim_{t-s \rightarrow 0} \frac{1}{t-s} \int (y-x) \cdot K(s, x, t, dy) = 0. \quad (\text{布朗运动没有漂移}). \quad \Rightarrow = b(s, x). \quad (-3) \text{ 线的斜率等于 } b. \quad \text{W.B. } \lim_{t-s \rightarrow 0} \frac{1}{t-s} \mathbb{E}[|X(t)-x| \geq \varepsilon | X(s)=x] = 0, \forall \varepsilon > 0.$$

$$\lim_{t-s \rightarrow 0} \frac{1}{t-s} \int (y-x)^2 \cdot K(s, x, t, dy) = 0^2. \quad (\text{正态分布的方差}). \quad \Rightarrow = \sigma^2(s, x). \quad (-3) \text{ 线的斜率等于 } \sigma^2.$$

(在无穷小的时间上由漂移不動)。

然后我们要说明：一个扩散过程可以与一个随机微分方程相联系。我们要写出扩散过程的 Kolmogorov 后向方程。

设我们有一个扩散 X_t ，有一函数 $f \in C_b(\mathbb{R})$ ，作用于 X_t 的一个“扩散”函数。对于某固定时刻 t ，我们将其期望值：

$$-\frac{\partial u(s, x)}{\partial s} = b(s, x) \cdot \frac{\partial u(s, x)}{\partial x} + \frac{1}{2} \cdot \sigma^2(s, x) \cdot \frac{\partial^2 u(s, x)}{\partial x^2}$$

证明: $\exists \tilde{s} < s+a < c$, 使得在 \tilde{s} 处
“函数在时间 t 时的期望上 $s+a$ 遍历所有可能路径。”

$$\begin{aligned} \frac{u(s, x) - u(s+a, x)}{a} &= \frac{1}{a} \left\{ \int_{x-y}^{u(s+a, y)} k(s, x, s+a, dy) - u(s+a, x) \right\} \\ &= \frac{1}{a} \left\{ \int_{|x-y| \leq \epsilon} [u(s+a, y) - u(s+a, x)] \cdot k(s, x, s+a, dy) + \int_{|x-y| > \epsilon} [u(s+a, y) - u(s+a, x)] \cdot k(s, x, s+a, dy) \right\} \\ &\quad \downarrow \text{对于 } \tilde{s} \text{ 而言 - 二项式 Taylor 展开} \\ &= \frac{\partial u(s+a, x)}{\partial x} (y-x) + \frac{1}{2} \cdot \frac{\partial^2 u(s+a, x)}{\partial x^2} (y-x)^2 + \text{高阶项}. \end{aligned}$$

设 $\Delta \rightarrow 0$, 则有 $I \rightarrow b(x, s) \cdot \frac{\partial u}{\partial x}, II \rightarrow \frac{1}{2} \sigma^2(s, x) \cdot \frac{\partial^2 u}{\partial x^2}$. 从而立刻得到结论。

进而, 若将括号内式子改写成: $k(s, x, a, dy) = p(s, x, t, y) dy$, 则代入后得立刻得证。

$$-\frac{\partial p}{\partial s} \left[\int f(y) \cdot p(s, x, t+y) dy \right] = b(s, x) \frac{\partial}{\partial x} \left[\int f(y) \cdot p(s, x, t+y) dy \right] + \frac{1}{2} \sigma^2(s, x) \frac{\partial^2}{\partial x^2} \left[\int f(y) \cdot p(s, x, t+y) dy \right].$$

$$\Rightarrow -\int f(y) dy \frac{\partial p}{\partial s} = \int f(y) dy \cdot \left[b \cdot \frac{\partial p}{\partial x} + \frac{1}{2} \cdot \frac{\partial^2 p}{\partial x^2} \right].$$

由 $p(s, x, y)$ 为随 x, s 的函数, 故后得此值条件: $p(t, x, t, y) = \delta(x-y)$.

在前面, 我们将随机时间 t 视作随机变量 $f(x)$ 的期望随着开始时间 s 和被抽位置 x 的变化。一种自然的想法是, 将开始固定而研究结果, 换言之, 期望 $E[f(x) | X(s)=x]$ 与 x 和 $X(s)$ 有关。

$$\frac{d}{dt} E[f(x_t) | X_s=x] \approx \frac{1}{a} \left\{ E[f(x_{s+a}) - f(x_s) | X_s=x] \right\} \text{ 内部} \downarrow \text{对于 } t \text{ 而言 - 二项式 Taylor 展开, 在今后遍历 } x_t \text{ 时遍历所有可能路径}.$$

$$\text{对于 } t \text{ 而言 - 二项式 Taylor 展开} = \frac{1}{a} \left\{ E \left[E \left[f(x_{s+a}) - f(x_s) | X_t=y \mid X_s=x \right] \right] \right\}$$

$$= \frac{1}{a} \left\{ E \left[E \left[\frac{\partial f(y)}{\partial y} (x_{s+a}-y) + \frac{1}{2} \frac{\partial^2 f(y)}{\partial y^2} (x_{s+a}-y)^2 | X_t=y \mid X_s=x \right] \right] \right\}$$

$$= \frac{1}{a} \left\{ E \left[\int \frac{\partial f(y)}{\partial y} (x_{s+a}-y) \cdot k(t, y, t+a, dy) + \frac{1}{2} \int \frac{\partial^2 f(y)}{\partial y^2} (x_{s+a}-y)^2 \cdot k(t, y, t+a, dy) | X_s=x \right] \right\}$$

$$= \mathbb{E} \left[\frac{\partial f(y)}{\partial y} b(t+y) + \frac{1}{2} \frac{\partial^2 f(y)}{\partial y^2} \sigma^2(t+y) \mid X_t=x \right]_{(y=x_t)}$$

从而我们得到 (3.7). $\frac{d}{dt} \mathbb{E}[f(x_t) \mid X_s=x] = \mathbb{E} \left[\frac{\partial f(X_t)}{\partial X_t} b(u, X_t) + \frac{1}{2} \frac{\partial^2 f(X_t)}{\partial X_t^2} \sigma^2(u, X_t) \mid X_s=x \right].$

这个形式比较通用，我们把它写开：设泛函 $K(s, x, t, dy) = p(s, x, t, y) dy$.

$\Rightarrow t, y$ 的对称性， $\frac{\partial}{\partial t}$ 是可微的。

$$\Rightarrow \int f(y) \frac{\partial p(s, x, t, y)}{\partial t} dy = \int p(s, x, t, y) \cdot \left[b(t, y), \frac{\partial f(y)}{\partial y} + \sigma^2(t, y), \frac{\partial^2 f(y)}{\partial y^2} \right].$$

$$\text{由分部积分出 } f(y) = \int f(y) dy \left[\frac{1}{2} \frac{\partial^2}{\partial y^2} (\sigma^2(t, y) p(s, x, t, y)) - \frac{\partial}{\partial y} (b(t, y) \cdot p(s, x, t, y)) \right]$$

由 $f(y)$ 的线性性得： $\frac{\partial p}{\partial t} = - \frac{\partial p}{\partial y} b + \frac{1}{2} \frac{\partial^2}{\partial y^2} (\sigma^2 \cdot p^2).$ 这正是所谓 forward - planck 方程。它给出了扩散过程中随时间的演化。