


## → A Brief history.

我们从“麦克斯韦妖”(Maxwell's demon)开始。假定有一个引擎叫A. 这个引擎，且有一小装置能自动识别的分子进入B. 而将更慢的分子留在A. 从而A的温度上升，反之。有一个类似的实验称为Szilard实验。它将一个只有2个活门的引擎体放在容器中，单独运行的腔体中。之后在容器中插入一活塞。若活塞向右移动，则将活塞向右移动，直至撞击容器，反向撞击。此过程循环往复。在每一种情况下，“The Agent”，将吸收一定热量 $W = kT \ln 2$ . 在这个过程中，活塞也可以被插入左侧位置。此时在一开始可以获取的功为： $-W = kT \ln p_A - p_B \ln \left(\frac{p_B}{p_A}\right) - (1-p_B) \ln \left(\frac{1-p_B}{p_B}\right)$ . 是相当的清晰。同样，你可能会想巨大的“信息引擎”。



以上展示了似违反了热力学第二定律。但请注意这是指宏观的和微观的。暂时把消息关于分子位置的比特信息。而微弱地增加这的信息需要做功。这就是 Landauer principle: 若要遵循可逆性时必须进行操作时。(例如对活塞的操纵或 computation path 的翻转)。此操作使你获得环境的熵增。是毫不矛盾。从以上“信息引擎”的视角。原路大相径庭。降低一个bit 所需要的能量为  $kT \ln 2$ ,  $\text{KJ}$ .

## → Back to Neg. Free Energy.

我们首先回顾 Gibbs 热力学的 part. 在前面，我们有  $F = \langle S \rangle - TS$ . 这里S是对一个系统直接度量的，而在热力学中，熵只可半经验定义。

我们引出所谓非常规的“负熵”。 $F^{\text{neg}}(p) = \langle S \rangle - kT \ln p$ . 我们要证明在所有满足条件的条件下： $p = p^{\text{eq}}$  时  $F^{\text{neg}}$  最小。证明如下：

$$\begin{aligned} \Delta F^{\text{neg}} &= F^{\text{neg}}(p) - F^{\text{neg}}(p^{\text{eq}}) \\ &= \frac{k}{2} \left[ (p \ln p - p^{\text{eq}} \ln p^{\text{eq}}) + kT \left( p \ln p - p^{\text{eq}} \ln p^{\text{eq}} \right) \right] \\ &= \frac{k}{2} p_x (2 \ln p + kT \ln p_x) - \frac{k}{2} p^{\text{eq}} (2 \ln p^{\text{eq}} + kT \ln p^{\text{eq}}) \\ &= \frac{k}{2} p_x (2 \ln p + kT \ln p_x) - F = \frac{k}{2} p_x (2 \ln p + kT \ln p_x - F) \\ &= \frac{k}{2} p_x (\ln p_x + kT - \ln p^{\text{eq}} - kT \ln p^{\text{eq}}) = kT \cdot D(p||p^{\text{eq}}) \geq 0. \quad \text{从而完成证明。并且我们找到了一个应用自然选择的 KL 熵度。} \end{aligned}$$

## → Information in Stochastic Thermodynamics.

回忆一下 Szilard Engine。我们将其升级为更复杂的对象 (obj) 和控制设备 (dev). 在这个模型中，叫它“飞机驾驶舱 (Cockpit)”。而 dev 也使用一个类 y-cells 来表示其状态信号。

在信息或信号，dev 与 obj 一起，不断更新信号。假定系统完全随机，从而系统的熵为： $S^{\text{sys}} = k \ln n = 2 \ln 2 = 2 \text{ KJ}$ .

在驾驶舱信号，不强的至  $kT \ln (L, L) / 2 \text{ KJ}$  两种。从而从总熵减少  $2 \ln 2 \text{ KJ} \cdot \ln 2$ . 且有两部分功：要对系统做功  $-T \Delta S^{\text{sys}} = kT \ln 2$  (假设系统已处于平衡态，即信息的分布是均匀的)。

可用于增加另一个子系统的熵，例如一个 memory.

那么来考虑一个至强/一致的情形。该 obj 可以处在线上。信息存储最佳；而 dev 处于记忆系统。均满足  $S_f = 0$ . 且 dev 处于平衡态。

任何 2 项的相对性可以由信息率表示:  $I(\text{obj}; \text{dev}) = \sum_{\text{obj}} \text{Pr}_{\text{obj}} \cdot \frac{\text{Pr}_{\text{obj}}}{\text{Pr}_{\text{obj}} + \text{Pr}_{\text{dev}}}$ . 在消息开始时, 我们完全不知道  $\text{Pr}_{\text{obj}} = \text{Pr}_{\text{obj}}^0$ , 有则通过估计  $\hat{\text{Pr}}_{\text{obj}} = \hat{\text{Pr}}_{\text{obj}}^0$ ,  $\text{Pr}_{\text{obj}} = \hat{\text{Pr}}_{\text{obj}}^0 \cdot \text{Pr}_{\text{obj}}$ .

这会是怎样的相对量呢?  $\Delta S^{sys} = S(\text{true}) - S(\hat{\text{true}}) = -k_B \sum_{\text{obj}} I(\text{Pr}_{\text{obj}}^0, \ln \text{Pr}_{\text{obj}}^0) - I(\text{Pr}_{\text{obj}}^0, \ln \text{Pr}_{\text{obj}})$ .

有个约束:  $-k_B I(\text{obj}; \text{dev}) = -\sum_{\text{obj}} \text{Pr}_{\text{obj}} \cdot \ln \frac{\text{Pr}_{\text{obj}}}{\text{Pr}_{\text{obj}} + \text{Pr}_{\text{dev}}}$ .

$$\Delta S^{sys} + k_B I = -k_B \sum_{\text{obj}} \text{Pr}_{\text{obj}}^0 \ln \text{Pr}_{\text{obj}}^0 + k_B \sum_{\text{obj}} \text{Pr}_{\text{obj}} \ln \text{Pr}_{\text{obj}} + k_B \sum_{\text{obj}} \text{Pr}_{\text{obj}}^0 \ln \text{Pr}_{\text{obj}}^0 - k_B \sum_{\text{obj}} \text{Pr}_{\text{obj}}^0 \ln \text{Pr}_{\text{obj}}.$$

$$= k_B \sum_{\text{obj}} (\text{Pr}_{\text{obj}}^0 \ln \text{Pr}_{\text{obj}}^0 - \text{Pr}_{\text{obj}}^0 \ln (\text{Pr}_{\text{obj}}^0 + \text{Pr}_{\text{dev}}))$$

$$= k_B \sum_{\text{obj}} (\text{Pr}_{\text{obj}}^0 \ln \text{Pr}_{\text{obj}}^0 - \text{Pr}_{\text{obj}}^0 \ln \text{Pr}_{\text{obj}}^0 - \text{Pr}_{\text{obj}}^0 \ln \text{Pr}_{\text{dev}})$$

$$\text{即: } \sum_{\text{obj}} \text{Pr}_{\text{obj}}^0 \ln \text{Pr}_{\text{obj}}^0 = \sum_{\text{obj}} \text{Pr}_{\text{obj}}^0 \ln \text{Pr}_{\text{dev}}.$$

$$\therefore \text{Pr}_{\text{obj}}^0 \ln \text{Pr}_{\text{obj}}^0 = \text{Pr}_{\text{dev}} \ln \text{Pr}_{\text{dev}}. \text{ 行为直角坐标系, 看着剩下的次元有: } \Delta S^{sys} = -k_B I(\text{obj}; \text{dev}) = -S^{sys}.$$

讨论 2 的相对有向量: 一部分来自  $\text{dev}$  对应于  $\text{Pr}_{\text{dev}}$  的梯度, 另一部分对应于  $\text{Pr}_{\text{obj}}$ , 通常在训练过程中  $\Delta S^{sys} < 0$ , 那么就有  $\theta = -T \Delta S^{sys}$  的梯度. 从而梯度方向.

有时的情况: 1). 训练并固定  $\text{dev}$  的梯度为 0, 即  $\Delta S^{sys} = 0$ . 此时, 所有的梯度用于增加  $\text{dev}$  和  $\text{obj}$  之间的距离.

2).  $\Delta S^{sys} = 0$ , 或称训练“僵化的”.  $I(\text{obj}; \text{dev}) = -\Delta S^{sys}$ . 从而梯度的梯度在“排放”到  $\text{dev}$  的过程中, 从而拉开  $\text{dev}$  的距离.

## • The Sagawa-Ueda Relation.

我们考虑 Feed back Control. 也就是说我们训练来改善 manipulated protocol. 假设  $i = \lambda(1 + \eta)$ . 对于一个随机行走加强. 我们可以定义一个物理上时刻的量和量差.

$$\text{lazy} = \ln \frac{\text{Pr}_{\text{obj}}^0}{\text{Pr}_{\text{obj}}^0 + \text{Pr}_{\text{dev}}} = \ln \frac{\text{Pr}_{\text{obj}}^0 \cdot \text{Pr}_{\text{dev}}^0}{\text{Pr}_{\text{obj}}^0 + \text{Pr}_{\text{dev}}^0} \quad \text{同理, 一条路径的梯度由两个量或两个量的形为:}$$

$$\underbrace{\text{Pr}_{\text{obj}}^0(\lambda)}_{\text{路径}} = \text{Pr}_{\text{obj}}^0(\lambda) \frac{\partial \lambda}{\partial \lambda}. \quad \text{从而, 我们可以有 Feed back Control 的梯度计算公式.}$$

第一部分将从  $\text{Pr}_{\text{obj}}^0$  到消息传递的梯度.

$$S^{true}(\text{obj}) / k_B = \ln \left[ \frac{\text{Pr}_{\text{obj}}^0(\lambda)}{\text{Pr}_{\text{obj}}^0} \right]. \Rightarrow -S^{true}(\text{obj}) / k_B = \ln \left[ \frac{\text{Pr}_{\text{obj}}^0(\lambda)}{\text{Pr}_{\text{obj}}^0} \right]. \Rightarrow -\frac{\partial \text{Pr}_{\text{obj}}^0(\lambda)}{k_B} - \text{lazy}(\text{true}) = \ln \left[ \frac{\text{Pr}_{\text{obj}}^0(\lambda)}{\text{Pr}_{\text{obj}}^0} \right] - \ln \left[ \frac{\text{Pr}_{\text{obj}}^0(\lambda)}{\text{Pr}_{\text{obj}}^0} \right]$$


$$\Rightarrow \exp \left( -\frac{\partial \text{Pr}_{\text{obj}}^0(\lambda)}{k_B} - \text{lazy}(\text{true}) \right) = \frac{\text{Pr}_{\text{obj}}^0(\lambda)}{\text{Pr}_{\text{obj}}^0} \cdot \frac{\text{Pr}_{\text{obj}}^0}{\text{Pr}_{\text{obj}}^0(\lambda)}. \quad \text{这样有:}$$

$$\langle \exp \left( -\frac{\partial \text{Pr}_{\text{obj}}^0(\lambda)}{k_B} - \text{lazy}(\text{true}) \right) \rangle = \int D\lambda \cdot d\eta \cdot \text{Pr}_{\text{obj}}^0(\lambda) \cdot \frac{\text{Pr}_{\text{obj}}^0(\lambda)}{\text{Pr}_{\text{obj}}^0} \cdot \frac{\text{Pr}_{\text{obj}}^0}{\text{Pr}_{\text{obj}}^0(\lambda)} = \int D\lambda \cdot d\eta \cdot \text{Pr}_{\text{obj}}^0(\lambda) \cdot \text{Pr}_{\text{obj}}^0 = 1.$$

令  $I = \langle \lambda \rangle$ , 从上面的方程可立刻看出  $W - \langle \eta \rangle \geq -k_B I$ .

## → The Mandel-Jozynski Machine.

该机器是一种可以读取两个输入并根据它们的值输出第三个值的简单机器。它有三个介面：A-B-C。



A  $\rightarrow$  B, B  $\rightarrow$  C, 有相同的映射。

ACOL: 在规则“1”下不能用，因为纸带被填满，无法起。


在 C  $\rightarrow$  A 的时候，纸带被填满。E2  $\rightarrow$  E1。

A, C 之间的映射不能用，因为  $\text{tanh}(m \cdot \text{cosh}) = \text{cosh}^{-1}(m \cdot \text{tanh})$ .

但是与一部计算机一样有 1 个而多于 1 个的输入和输出端。


A, B, C 三个端点为单线的。输出端口由 Agent 管理。该端口 A-C 由 Agent 管理。Agent 对 machine 是透明的。

输出端口是  $k_{AC} = 1 - 3$ ,  $k_{CA} = 1 - 3$ ,  $g = \tanh(m \cdot \text{cosh}) / \text{cosh}$ 。这东西有阻塞。



## → Copying Information.

在生命体内，通常存在对于信息高要求且耗能高的复制行为。通过单链 DNA 复制、转录，这一过程往往耗能很高。例如  $x_0(x_1, y) \rightarrow (x_1^1, y)$ ,  $x_1^1 = x_1 \cdot \text{XOR } y$ . 所以，这样过高的信息复制成本是不必要的。不需要 Landauer Bound 中的功耗限制。具体来说，我们看到如下模型：



假设主链中有滑块运动 S, 从 P 到 P' 时速率设置为  $k_{P \rightarrow P'} = w_P \cdot e^{S/kT}$

在副链 P' 上进行的步骤可以加入更慢的新的速率（但同时加入错误率）。加入  $\frac{(+)}{(-)}$  率为  $k_{P' \rightarrow P''}$  和慢速  $k_{P'' \rightarrow P'''}$ 。从而得到 jump network 类似于同一链上发生的转移过程。 $\begin{array}{ccc} P & \xrightarrow{k_{P \rightarrow P'}} & P' \\ & \xrightarrow{k_{P' \rightarrow P''}} & P'' \\ & \xrightarrow{k_{P'' \rightarrow P'''}} & P''' \end{array} \xrightarrow{\text{loop}} \text{loop/m}^{-1}$

假设主链中有滑块运动 S, 从 P 到 P' 时速率设置为  $k_{P \rightarrow P'} = w_P \cdot e^{S/kT}$

$k_{P \rightarrow P'} = k_{P'} + k_{P' \rightarrow P''} + k_{P'' \rightarrow P'''} - (k_{P'' \rightarrow P'''} + k_{P'' \rightarrow P''}) P'''$

由于速率是单向的，所以不能分解成两个部分。由于我们的前一个条件已经设置，所以前一个条件对一个通过正确的转移  $P \rightarrow (-) \rightarrow (+) \rightarrow (-) \rightarrow (+) \rightarrow (-)$  得到的转移速率没有影响。

从 P 到 P' 的速率  $\frac{d}{dt} = \frac{k_{P \rightarrow P'} - k_{P' \rightarrow P''}}{k_{P'' \rightarrow P'''} + k_{P'' \rightarrow P''}}$ 。从而，主链的速率恒定。 $v = k_{P \rightarrow P'} + k_{P' \rightarrow P''} - (k_{P'' \rightarrow P'''} + k_{P'' \rightarrow P''})$ 。

我们如何计算转移速率？

1). Eq. Linear: 适用于简单的猜测。对可用的方程进行求解。得到  $\eta^{eq} = \frac{\exp(-\alpha S/kT)}{\exp(-\alpha S/kT) + \exp(-\alpha S'/kT)}$

$$\eta^{eq} = \frac{\exp(-\alpha S/kT)}{\exp(-\alpha S/kT) + \exp(-\alpha S'/kT)}$$

“关键”能量  $\delta_{\text{stall}} = \epsilon_R + kT \ln(1 - \eta^{eq})$ 。当  $\delta < \delta_{\text{stall}}$ ，系统将永远停在平衡线上。

2). Fully Inversible Limit: 对非常大的 driving 力而言， $\eta = k_{P'} / (k_{P'} + k_{P''}) = w_P / (w_P + w_{P'})$ 。

在  $\delta \ll \delta_{\text{stall}}$ ，还尚未上升的过程，无法将从一个转移移动到另一个转移的速率匹配（注意，两个转移的速率是不同的）。

另外, 从图中可以看出, 在不同的环境条件下, 热力学信息量是不同的: (左) 热力学信息量小; (右) 热力学信息量大。

$$TS^{info} = k_B T \left[ T^2 \cdot \ln \left( \frac{k_B}{T} (1 - p) \right) + T^2 \cdot \ln \left( \frac{k_B}{T} p \right) \right] = k_B T \left[ \Delta W - \alpha T \cdot \ln \left( \frac{\Delta W}{k_B T} \right) \right] \geq 0.$$

其中  $T$  是所有一系列事件的温度,  $\Delta W = S_{final} - S_{initial}$ ,  $\alpha = k_B T \cdot \ln \left( e^{-\frac{W}{k_B T}} + e^{-\frac{W}{k_B T}} \right)$ .

## ④ Information Cost in sensing

在实验中, 我们通常需要记录许多随时间变化的信号和一段时间内的平均值, 并将它们与先前测量的信号进行比较。sensory-adaption system.

我们假设单个的信号为: 信号  $a$ , 信息  $e$  (或  $\alpha$ ). 信号的熵即为  $S(a)$ , 信息的熵即为  $S(e)$ . 信号的平均值即为  $\bar{a}$ , 信息的平均值即为  $\bar{e}$ .

信息  $\Sigma = \Sigma_{a,m,e} = S(a) + S(m) + S(e)$ . 定义有  $\Delta a = \bar{a} - a$ , 适应系数  $\alpha = \alpha(a, m, e)$ ;  $\alpha = \alpha(a, m, e)$  表示  $a$  的适应率, 即当  $a$  变化时,  $m$  和  $e$  的变化程度。

$$\Sigma_{a,m,e} = 10^{-m} \left[ (\Delta m + 1) a - \alpha \Delta a \right]$$

$$\text{且 } \Delta a/m = -k_B T \cdot \ln S(a/m).$$

为了简化起见, 我们认为  $a/m$  的引数不会同时改变, 即  $\Delta a/m = \Delta a \cdot \exp \left( \Sigma_{a,m,e} / k_B T \right)$ ,  $\Delta a/m = \Delta a \cdot \exp \left( \Sigma_{a,m,e} / k_B T \right)$ .

利用  $S(a)$  的“偏移”来计算信息熵:  $I(\text{sys}: \text{env}) = \sum_{a,m,e} P_{a,m,e} \ln \frac{P_{a,m,e}}{P_a P_m P_e} = \sum_{a,m,e} P_{a|m,e} P_e \ln \frac{P_{a|m,e}}{P_e}$  利用引数的偏移计算信息熵:

$$I(\text{sys}: \text{env}) = \sum_{a,m,e} P_{a,m,e} \ln \frac{P_{a|m,e}}{P_{a|m,e}} + \sum_{a,m,e} P_{a|m,e} P_e \ln \frac{P_{a|m,e}}{P_{a|m,e}}$$

$$= I(\text{mem}: \text{env}) + I(\text{aureon}: \text{mem}).$$

这个计算公式可以写成  $I(\text{sys}: \text{env}) = \sum_{a,m,e} P_{a|m,e} \ln \frac{P_{a|m,e}}{P_{a|m,e}}$ . 信息  $\Sigma$  与  $P_{a|m,e}$  的关系和对于  $\Delta a/m$  的操作。

$$\left\{ \begin{array}{l} \Delta I_{\text{mem}} (n = I(\text{sys}: \text{env})) - I(\text{sys}: \text{env}) \\ \Delta I_{\text{aureon}} (n = I(\text{sys}: \text{env})) - I(\text{sys}: \text{env}) (n = I(\text{mem})) \end{array} \right. = \sum_{a|m,e} P_{a|m,e} \ln \frac{P_{a|m,e}}{P_{a|m,e}}, \quad P_{a|m,e} = \frac{P_{a|m,e}}{P_{a|m,e} + P_{a|m,e}}$$

$$= I(\text{mem}: \text{env}) + I(\text{aureon}: \text{mem}).$$

上面的表达式是正确的, 在对  $\Delta a/m$  的操作,  $\Delta a/m$  的操作, 这是通过  $\Delta a/m$  来实现的。

所以  $I(\text{sys}: \text{env}) = \sum_{a|m,e} \langle \Sigma_{a|m,e} \rangle P_{a|m,e}$ . 在信息处理过程中, 有一部分是需要优化的。

信息熵:  $S_{\text{rec}}(n) = \Delta S_{\text{aureon}}^{sys} + S_{\text{aureon}}^{sys}$ . (S<sub>rec</sub> = S<sub>rec</sub> + S<sub>rec</sub>)

$$\Delta S_{\text{aureon}}^{sys} = k_B \left[ n \cdot \ln \left( P_{a|m,e}(n) \right) - n \cdot \ln \left( P_{a|m,e}(n_0) \right) \right]$$

$$S_{\text{rec}}(n) = \frac{1}{n} \sum_{a|m,e} \langle \Sigma_{a|m,e} \rangle = \frac{1}{n} \left( \langle \Sigma_{a|m,e} \rangle_{P_{a|m,e}} - \langle \Sigma_{a|m,e} \rangle_{P_{a|m,e}(n_0)} \right)$$

注意,  $n$  是一定的,  $S_{\text{rec}}$  是不变的。

图 3 信息熵与测量(measure)前的信号和与操作(erasure)后的信号, 保持不变。

$$H(\text{sys}: \text{env}(n), \text{env}(n_0)) = H(\text{sys}: \text{env}(n)) - I(\text{sys}: \text{env}(n) | \text{env}(n_0)).$$

$$= H(\text{sys}) - \underbrace{I(\text{sys}: \text{env})}_{\text{measure}} - \underbrace{I(\text{sys}: \text{env}(n) | \text{env}(n_0))}_{\text{erasure}}$$

$$\frac{\partial H(\text{sys}, \text{env})}{\partial n} = -k_B \frac{\partial}{\partial n} \ln \left( P_{a|m,e}(n) \right) \geq 0.$$

说明, 信息熵随  $n$  增加而增加。

设  $\lim_{t \rightarrow +\infty} \theta = w - (\alpha\delta) \cdot 20$ ,  $\Delta F = (\alpha\delta) - k_B T \cdot \ln(1 + e^{-\frac{E}{k_B T}})$ .

$$w - (\alpha\delta) \cdot 20, \quad (\alpha\delta) = \Delta F + k_B T \cdot \ln(1 + e^{-\frac{E}{k_B T}}) \Rightarrow w - \Delta F - k_B T \cdot \ln(1 + e^{-\frac{E}{k_B T}}) \geq w - \Delta F \geq k_B T \cdot \ln(1 + e^{-\frac{E}{k_B T}}). \text{ 从而有:}$$

$$w - \Delta F = k_B T \cdot [\ln(systime; envsys) - \ln(systime; envsys')]. = k_B T \cdot \alpha \Delta t \cdot \theta.$$

$$\{ T \cdot \alpha \Delta t \cdot \theta = k_B T \cdot [\ln(systime; envsys) - \ln(systime; envsys')]. = k_B T \cdot \alpha] \Delta t \cdot \theta \geq 0.$$

根据上面的推导，我们可以得出如下的结论：在相同 signal 的时候，更多的消息被发送到低级别的线程，从而消耗更多的功；而保障消息的顺序会有更高的功。

对于很重要的消息，尤其是物理性的消息，它们通常位于不满足精确定时的非平衡种类上。对于这样的消息，以上等式是成立的，因为可以将 OS 分为  $OS^{sa}, OS^{na}$ 。通过证明。

## → Information Reservoirs.

首先，我们已经识别了两种不同的情形，分别为  $Szilard$  情形和  $M-T$  机器。然后，我们引入一个熵-框架，来说明如何在  $Szilard$  和  $M-T$  机器上操作某种信息源。

$$\text{简单起见，我们设 } \theta = \text{��} \Rightarrow \dot{\theta} = 0. \quad \Sigma_{down} = 0. \quad \Sigma_{up} = \epsilon > 0. \quad \text{令热浴在温度为 } T \text{ 的热障中。从而立刻有: } p_{up} = \frac{1}{1 + \exp(-\epsilon/k_B T)}, \quad p_{down} = \frac{\exp(-\epsilon/k_B T)}{1 + \exp(-\epsilon/k_B T)}. \quad \text{对应的 } \frac{\partial \theta}{\partial \epsilon} = \frac{1}{k_B T^2} = \exp(-\frac{\epsilon}{k_B T}).$$

然后，除了热障之外，还有一个信号障，不能与信号库互通的速率  $\eta$ 。若信号速率高，并发量少，则信号到热障的速率，并发量低，则  $\eta$  反之亦然。

具体来说，“精确定时”的进程从信号库中抽一个信号，并且将信号的速率写为抽取的速率。所以不知道信号库中信号的速率，或者为  $0$ 。从而由信号库引起的熵的跳跃率为:  $\dot{\theta}^s = \eta \eta \quad \dot{\theta}^d = \eta(1-\eta)$ 。

与信号库相关的主过程和子过程的速率发生变化。有: (此时，信号在外部/信号库内与热障处于非平衡状态)

$$\left\{ \begin{array}{l} \frac{dp_u}{dt} = (k^u + \dot{\theta}^s) \cdot p_u - (k^d + \dot{\theta}^d) \cdot p_d \\ \frac{dp_d}{dt} = (k^d + \dot{\theta}^d) \cdot p_d - (k^u + \dot{\theta}^s) \cdot p_u \end{array} \right. \Rightarrow \left\{ \begin{array}{l} p_u^s = \frac{k^u + \dot{\theta}^s}{k^u + \dot{\theta}^d} \\ p_d^s = \frac{k^d + \dot{\theta}^d}{k^u + \dot{\theta}^s} \end{array} \right. \text{下面考虑如何使用这样一套进阶模型的用途}$$

→ Measurement of Feedback 首先一个重要的反馈机制就是，信号的发送和接收的速率测量。 $\dot{\theta} = \dot{\theta}^s + \dot{\theta}^d$ . 对于  $Szilard$ ，反馈是直接的。对于  $M-T$ ， $\dot{\theta}^s = \dot{\theta}^d = \dot{\theta}$ 。 $P_{idle} = P_{idle}^s = 1 - \dot{\theta}$ 。 $P_{idle} \approx P_{idle}^s \approx \tau$ .

这样我们就能发现  $\dot{\theta}$  jump rate 还原了熵模型。 $dev$  作出 2 的概率 (即右一信号障，不被立刻处理的概率) 为  $p_{dev} = 1 - \dot{\theta}^s \cdot p_u^s + \dot{\theta}^d \cdot p_d^s = p_u^s + \dot{\theta} - \dot{\theta} \cdot p_u^s$ 。

而单位时间内，外界对系统做功:  $w = \dot{\theta} \cdot \theta \cdot [1 - p_u^s - (1-\dot{\theta}) \cdot p_d^s] = \alpha \delta, (p_u^s - \tau)$ . 当系统处于非平衡状态时， $w$  为单位时间由信号向热障做功  $\dot{\theta} \cdot \theta \cdot \delta$ ，或  $w = \dot{\theta} \cdot \theta \cdot \delta$

对于对于非平衡的速率的计算，其  $dev$  和  $systime$  的功为:  $I = H(dev) - H(dev) + \dot{\theta} \cdot \theta \cdot \delta = H(dev) + \dot{\theta} \cdot \theta \cdot \delta$ 。对于信号加权的功  $\eta \cdot \dot{\theta}$ 。 $w + k_B T \geq 0$ 。对于信号元器件的功  $\dot{\theta} \cdot \theta \cdot \delta$ 。 $w + k_B T \geq 0$

→ TAPF 在  $T=0$  机器中，信号库由信号充当，以  $\dot{\theta}$  的速率输出信号运动。若信号上的工被更新叫  $update$  系统。若不满在某一时刻通过与热障接触降低了功率，则信号上的 bit 也被屏蔽。从这个阶段，系统的功加量和增加的功完全相同。\* 在这样系统下，热障的 / 高开销的 bit 为功的功加量  $\eta$  和  $\dot{\theta}$ 。从而，信号上的功加量是  $\eta \cdot \dot{\theta}$ 。 $[H(sys) - H(un)]$ .

$$TAPF_{TAPF} = w + \dot{\theta} \cdot \theta \cdot [H(sys) - H(un)] \geq 0. \Rightarrow \dot{\theta} \cdot \theta \cdot T [D_K(p_{idle}^s) - D_K(p_{idle}^d)] \geq 0.$$

从这里可以推出若  $H(sys) - H(un) < 0$ 。此时和信号 eraser 一样。 $\Rightarrow w > 0$ .

→ Generalized Detailed Balance. 另外一种方法，我们可以使用背向误差率以期产生。


$$S_{DBB}^{tot} = k_B \left( k^u p_u^s - k^d p_d^s \right) \ln \frac{k^u}{k^d} + k_B \left( \dot{\theta}^d \cdot p_u^s - \dot{\theta}^s \cdot p_d^s \right) \ln \frac{\dot{\theta}^d}{\dot{\theta}^s}$$

在两个不同的情形下，我们得到了三个不同的熵产生。这是因为对于和TAPE中我们其实忽略了一部分熵产生。e.g. 在CPU中，我们忽略了dev获得和擦除信息的熵。在TAPE中，我们忽略产生纸带初始熵。

### Fluctuation Relations with Information reservoirs.

前面有一些不等式，这些不等式可以用来计算熵不增加。之前，我们知道有些系统不会导致Bd。 $\bar{F}_d = \sigma(t-t)$ 。 $F_d = \sigma^t$ 。我们更加强调

我们感兴趣的两个Copy A, B。每当信息存储时我们从一个Copy转至另一个。从而我们有状态。 $x \in \{d, u\}$ ,  $\alpha \in \{A, B\}$ .



现在我们从BD 不同于信息存储的互信息导致高熵到熵。对信息存储的存储（或对信息存储的不同描述），将导致这一部分的熵被算到不同组件。这在路径的向后， $k^*$  变得不清楚。但 $\bar{F}_d$ ,  $k_u$ ,  $k_d$  要发生变化。且之后的讲授我们将改变。 $\bar{F}_d \rightarrow \bar{F}_d = \bar{F}^* + \bar{f}_u = r$ 。从而由正向路径的相对比，我们可以求解问题。

$$\frac{P_x(k, \bar{F}, \text{bd})}{P_x(k, \bar{F}, \text{bd})} = \frac{P_{x,u}^{st}(x,u)}{P_{x,d}^{st}(x,d)} \exp\left(\frac{1}{k_B} S^{\text{reg}}(x)\right) = \exp\left(\frac{1}{k_B} S^{\text{reg}}(x)\right).$$

$$S^{\text{reg}} = \underbrace{-\frac{1}{2} k_B \cdot \frac{1}{k_{x,u}} \ln(k_{x,u})}_{\text{热力学的熵}} \underbrace{-\frac{1}{2} k_B \cdot \frac{1}{k_{x,d}} \ln(k_{x,d})}_{\text{信息存储的熵}} + k_B \cdot \underbrace{\ln \left( \frac{\bar{F}_d}{\bar{F}^*} \right)}_{\text{路径的熵}}.$$

从上图可以看出不同路径的熵是不同的，因为虽然路径是通过与热力学途径进行的，而从“热力学的热 Copy 途径”的途径，即为这些步骤是通过与信息存储无关的。

JWK 例题：若  $(S_{x,d}^L, S_{x,u}^L, S_{x,d}^R, S_{x,u}^R, S_{x,d}^F, S_{x,u}^F, S_{x,d}^H, S_{x,u}^H)$ ， $P_{x,u} = \frac{1}{2} \delta_{x,d}^L \delta_{x,u}^R \delta_{x,d}^F \delta_{x,u}^H + \frac{1}{2} \delta_{x,u}^L \delta_{x,d}^R \delta_{x,u}^F \delta_{x,d}^H$  大布热，即的热力学途径被算到，而并非在 JW 中被算到。

我们只取那些这样的东西确实是正弦途径的组成部分，必须用之。一条路径的组成由跳跃概率和在路径上保持概率来乘得到。由于  $\bar{k}_d + \bar{k}_d = \bar{k}^* + \bar{k}_d = \bar{k}^* + \bar{k}_u = r$ ，所以加上热的路径上从热存储的熵是一样的。这样我们仍不需要在跳跃概率。

$$\frac{P_x(k, \bar{F}, \text{bd})}{P_x(k, \bar{F}, \text{bd})} = \frac{P(x)}{P(x)} \quad (\text{相同一套跳跃概率}) \cdot \frac{P(x)}{P(x)} \quad (\text{不同 Copy 间跳转})$$

$$= \frac{N \cdot C \cdot \theta \cdot n^2}{\pi} \cdot \frac{k_{\text{avg}} \cdot k_{\text{rel}}}{k_{\text{avg}} \cdot k_{\text{rel}}} \quad (\text{若 } x_1, x_2 \text{ 同向则 } \text{copy})$$

$$\frac{k_{\text{avg}} \cdot k_{\text{rel}}}{k_{\text{avg}} \cdot k_{\text{rel}}} \quad (\text{若 } x_1, x_2 \text{ 反向则 } \text{not copy})$$

以下从最简单的单链表开始，依次是二叉树的四种，从而我们有三张图表。\$\left( \operatorname{opt} \left( -\frac{s^{\text{tot}}}{k\_{\text{rel}}} \right) \right) = 1\$. w.b. \$\langle s^{\text{tot}} \rangle \geq 0\$.

理解了，对数平衡性保证的性质，在任何一棵树的进程中，不断有操作发生。

$$s^{\text{tot}} = \lim_{T \rightarrow \infty} \frac{\langle S^{\text{MC}} \rangle}{T} = \frac{1}{2} k_B \cdot \frac{T_{\text{avg}}}{k_{\text{rel}}} \cdot T_{\text{avg}} \cdot \ln \frac{k_{\text{rel}}}{k_{\text{avg}}} + k_B \cdot \frac{T_{\text{avg}}}{k_{\text{rel}}} \cdot T_{\text{avg}} \cdot \ln \frac{k_{\text{avg}}}{k_{\text{rel}}} \geq 0. \quad \text{其中 } T_{\text{avg}} \cdot T_{\text{rel}} \text{ 是树叶平均数的总和}.$$

$$\begin{cases} \text{Int} = k_{\text{rel}} p_{\text{rel}} - k_{\text{avg}} p_{\text{avg}} \\ \text{Ext} = \bar{k}_{\text{rel}} p_{\text{rel}} \end{cases} \quad (\text{注意这里 } \bar{k}_{\text{rel}} \text{ 是树中子节点的平均数})$$

下面我们将证明，对于 \$f\$ 的不同选取对应的对信息熵的不同的贡献率。

> 对于 Measurement and Feedback. 选取 \$f\_{\text{int}} = f\_{\text{ext}} = \bar{s} \cdot p\_{\text{dev}}\$. \$f\_{\text{int}} = f\_{\text{ext}} = \bar{s} \cdot p\_{\text{dev}}\$. 从上立刻得到期望结果。

$$s^{\text{tot}}_{\text{MF}} = \frac{1}{2} k_B \cdot \frac{T_{\text{avg}}}{k_{\text{rel}}} \cdot T_{\text{avg}} \cdot \ln \frac{k_{\text{rel}}}{k_{\text{avg}}} \rightarrow \bar{s} \cdot k_B [m_{\text{dev}} - m_{\text{int}}] \geq 0.$$

> 对于 TAPE. 由于 \$f\_{\text{int}} = f\_{\text{ext}} = \bar{s} \cdot p\_{\text{dev}}\$. \$f\_{\text{int}} = \bar{s} \cdot p\_{\text{dev}}\$. \$f\_{\text{ext}} = \bar{s} \cdot p\_{\text{dev}}\$. \$s^{\text{tot}}\_{\text{TAPE}} = \frac{1}{2} k\_B \cdot \frac{T\_{\text{avg}}}{k\_{\text{rel}}} \cdot T\_{\text{avg}} \cdot \ln \frac{k\_{\text{avg}}}{k\_{\text{rel}}} + k\_B \cdot \bar{s} \cdot [m\_{\text{dev}} - m\_{\text{int}}] \geq 0.

> 对于 Generalized Detailed Balance. 定义上是最复杂的模型。\$\hat{f}\_{\text{int}} = k\_{\text{rel}}\$. 从上等式。

$$s^{\text{tot}}_{\text{GDB}} = \frac{1}{2} k_B \cdot \frac{T_{\text{avg}}}{k_{\text{rel}}} \cdot T_{\text{avg}} \cdot \ln \frac{k_{\text{rel}}}{k_{\text{avg}}} + k_B \cdot \bar{s}' \cdot \ln \frac{1}{p} \geq 0. \quad \bar{s}' = \bar{s} \cdot p_{\text{rel}} - \bar{s} \cdot p_{\text{avg}}$$

三种情况下的期望值有关系：

$$\begin{cases} \hat{s}^{\text{tot}}_{\text{GDB}} - \hat{s}^{\text{tot}}_{\text{TAPE}} = k_B \cdot p_{\text{FL}} \cdot (p_{\text{dev}} - p_{\text{int}}) \geq 0 \\ \hat{s}^{\text{tot}} - \hat{s}^{\text{tot}}_{\text{TAPE}} = k_B [m_{\text{dev}} - m_{\text{int}}] \geq 0 \end{cases}$$

通过以上一个例子，可以看出同时保证信息熵正负，而且不违反平衡性的两个条件，即 \$p\_{\text{FL}} \geq 0\$。  
这个结果与一般的热力学第二定律在概念上完全相同。

在信息熵上的影响比平衡性的强弱相对，修正项也是可以使用的。