

“勇敢的少年啊，快去创造奇迹！”

→ Stochastic Efficiency

对于地热和预言，Carrie 完全给出的都是“肯定还是‘可能的’！因为它是属于热力学的事件”。而并不属于“神秘学”领域的“事件”。

在不利，我们通过做功使之改变，看后面的“热力学第一定律”。物体做功输入它的内能上升，而我们从热力学第一定律得知，从而热能的熵要减小，从而我们用熵定一个热机的效率。

$\eta_s = -S_{\text{in}} / S_{\text{out}}$. 由于热平衡 Carnot 定律. 必有 $\eta_s \leq 1$.

对于某一个确定的量，我们可以定其依赖关系 $\eta = -\frac{\sin \theta}{\sin \alpha}$ 。为了研究其性质，首先应用解微分方程的方法。 $P(Sin \theta | Sin \alpha) = \exp \frac{1}{k_B} (-\sin \theta + Sin \alpha)$

注意，布雷文说，我们应从这个新的特性而将属性限制于字符串。即 $s(1)=s(2)$

$$\begin{aligned}
 \text{BEMMA}(z, \theta; p(\mathbf{x}^{\text{in}}, \mathbf{s}^{\text{out}})) &= \int d\mathbf{x} \cdot \delta(\sin - \sin(\theta)) \cdot \delta(\mathbf{s}^{\text{out}} - \mathbf{s}^{\text{out}(\mathbf{x})}) \cdot p(\mathbf{x}) \\
 &= \int d\mathbf{x} \cdot \mathbf{s} \cdot (\sin - \sin(\theta)) \cdot \delta(\mathbf{s}^{\text{out}} - \mathbf{s}^{\text{out}(\mathbf{x})}) \cdot \exp(S^{+t}(\vec{x})) \cdot p(\mathbf{x}) \\
 &= e^{S^{+t}(\vec{x}) / kT} \cdot \int d\mathbf{x} \cdot \delta(\mathbf{s}^{\text{in}} + \mathbf{s}^{\text{out}(\mathbf{x})}) \cdot \delta(\mathbf{s}^{\text{out}} + \mathbf{s}^{\text{out}(\mathbf{x})}) \cdot p(\mathbf{x}) \\
 &= \exp(S^{\text{tot}(\mathbf{x})} / kT) \cdot p(-s^{\text{in}}, -s^{\text{out}}).
 \end{aligned}$$

在长期的斗争下，壮大革命力量，我们有

$$\frac{\exp(-E(j^{\text{in}}, j^{\text{out}}), T)}{\exp(-E(j^{\text{in}}, j^{\text{out}}), T)} = \exp(E(j^{\text{in}}, j^{\text{out}})/k_B) \cdot \text{rate function} = \exp(-E(j^{\text{in}}, j^{\text{out}}) + k_B E(j^{\text{in}}, j^{\text{out}})) = e^{k_B E(j^{\text{in}}, j^{\text{out}})}$$

fp addate function 調用於插入資料時， $\text{f}(y) = \min_{j \in \text{in}} \frac{\text{f}(\text{j}^{\text{in}}, \text{j}^{\text{out}})}{\text{j}^{\text{in}}, \text{j}^{\text{out}} > \text{v}^{\text{in}} / \text{v}^{\text{out}} = 1}$

$\Rightarrow I\left(\frac{f_0 = -J \sin}{J \cos} \right) = \min_{f_0} I(f_0, \dots) = 0$. 因此在 ensemble 的平均熵意义上, 熵函数达到极小值. 这是正确的.

我们有另一个方案: 取 $\frac{1}{j_1} = \frac{1}{j_2} = 1$ 时的情形. 有 $I(j_1^{10}, j_2^{10+4}) = I(-j_1^{10}, -j_2^{10+4})$. 从而 $I(j_1^{10}, -j_2^{10+4})$ 是 j_2^{10} 的线性函数. 从而它的系数

$$\text{mfp. } Z(\eta) = 2 \left(\sin^{-1} \sqrt{\eta^2 + 1} \right) - \sin^{-1} \sqrt{\eta^2 + 1} = 0.$$

从而证明了 T_0 在 T 时取得最大值。换言之， $Carnot$ 不是随机热机¹⁰最不可能达到的。

下而的 μ_{GOF} 是 χ^2 -fit 的 scaled GOF to $\psi^{(\text{GOF})}$ ($\chi^2_{\text{GOF}} = \lim_{T \rightarrow \infty} \frac{1}{T} \ln(\exp(\chi^2_{\text{GOF}}) + \text{gof}_{\text{GOF}})$)

$\hat{f} = \inf_{g \in \mathcal{G}} \text{Var}_{\mu} (g^*(x_1, x_2))$ ($g + g_{\text{out}}, \eta, g_{\text{out}}$). Var_{μ} STOCC 算法

$$\begin{aligned}
 \text{Imp} &= \inf_{j \in J^n} I(j^{in}, -n_j j^{in}) \\
 &= \inf_{j \in J^n} \sup_{q_{in}, q_{out}} [q_{in} j^{in} - q_{out} (j^{in}, j^{out}) - \psi^{(j^{in}, j^{out})}(q_{in}, q_{out})] \\
 &= \inf_{j \in J^n} \sup_{q_{in}, q_{out}} [j^{in} (q_{in} - q_{out}) - \psi^{(j^{in}, j^{out})}(q_{in}, q_{out})] \quad \text{let } q = q_{in} - q_{out} \\
 &= \inf_{j \in J^n} \sup_q [q \cdot j^{in} - f(q)] \quad \text{引入一个辅助变量 } q. \text{ 从而问题转化为一元函数. } f(q) = 0 \\
 &= -\sup_{j \in J^n} [\sup_q (q \cdot j^{in} - f(q))] \quad q = 0 \\
 &= -f(0). \quad = -\inf_{q_{out}} \psi^{(j^{in}, j^{out})}(q_{out}, q_{out})
 \end{aligned}$$

1

利用上面推出的公式进行计算有: $T(q) = \frac{1}{2} \cdot \frac{C(s^{in}, 1 + s^{out})^2}{\tilde{s}^{in}^2 + 1 + C_{in,out} + \tilde{s}^{out}}.$ 由于 Scaled CGF 对称性, $q_1(s^{in}, s^{out}) = q_1(s^{in}, \tilde{s}^{out})(-t_0 - q_{in}, -\frac{1}{t_0} - q_{out}).$ 我们实际上只需要计算 $\tilde{s}^{in} = \tilde{s}_{in} + \tilde{C}_{in,out}$, $\tilde{s}^{out} = \tilde{s}_{out} + \tilde{C}_{in,out}$, 可以通过改写得来.

→ Uncertainty Relations

在证明中，我们称使用以弱序 bound 估计 empirical current 的弱序的先验不相容的先验。也就是说，不相容并不意味着一个“精确”的、确定性的先验需要很细的精度。

是中和音，我们能得到 new current J . W 及 J 在一段时间内为 $\exp(S^{stop})$ 的那部分频率。它满足关系 $p(S^{start})/p(S^{stop}) = \exp(S^{stop}/k_B)$ 。下面证明。

$$\begin{aligned}
 p(s^{tar}, j) &= \int D\alpha \cdot \delta(s^{tar} - s^{tar}(\alpha)) \cdot \delta(j - j(\alpha)) \cdot p_{\alpha} \\
 &= \int p_{\alpha} \cdot \delta(s^{tar} - s^{tar}(\alpha)) \cdot \delta(j - j(\alpha)) \cdot \exp(s^{tar}(\alpha)) p(\alpha) \\
 &= \int p_{\alpha} \cdot \delta(s^{tar} + s^{tar}(\alpha)) \cdot \delta(j + j(\alpha)) \cdot \exp(s^{tar}(\alpha)) p(\alpha) \\
 &= \int p_{\alpha} \cdot \delta(s^{tar} + s^{tar}(\alpha)) \cdot \delta(j - j(\alpha)) \cdot \exp(s^{tar}(\alpha)) p(\alpha) \\
 &= \exp(s^{tar}(\alpha)/\alpha_0) \cdot p(-s^{tar} - j).
 \end{aligned}$$

这个证明同时用到了 Current 和 Previous 两个操作的线性组合的可加性

所以 $\mu = -\ln(1-p)$ 是随机变量的极点分布。 $P(X \geq t) = (1-p)^t = e^{-\mu t}$ 。

$$p^+(s^{**}, t) = p(s^{**}, t) + p(-s^{**}, -t), \text{ 且有}$$

$$\int_0^{+\infty} ds^{**} \int_{-t}^{+t} dt, p^+(s^{**}, t) = \int_0^{+\infty} \int_{-\infty}^{+\infty} ds^{**} dt, p(s^{**}, t) + \int_0^{+\infty} \int_{-\infty}^{+\infty} ds^{**} dt, p(-s^{**}, -t) = 1, \text{ 且有 } p^+(s^{**}, t) = 1.$$

$$\begin{aligned} \langle T \rangle &= \int_{-\infty}^{+\infty} ds^{**} \int_{-t}^{+\infty} dt, J \cdot p(s^{**}, t) \\ &= \int_0^{+\infty} ds^{**} \int_{-t}^{+\infty} dt, J \cdot p(s^{**}, t) - \underbrace{\int_0^{+\infty} ds^{**} \int_{-t}^{+\infty} dt, J \cdot p(s^{**}, t) \cdot (\exp(-s^{**}/k_B))}_{\downarrow} \\ &= \int_0^{+\infty} ds^{**} \int_{-t}^{+\infty} dt, J \cdot p(s^{**}, t) \cdot (1 - \exp(-s^{**}/k_B)) \\ &= \int_0^{+\infty} ds^{**} \int_{-t}^{+\infty} dt, J \cdot p^+(s^{**}, t) \cdot \frac{1 - \exp(-s^{**}/k_B)}{1 + \exp(-s^{**}/k_B)} = \left\langle J \cdot \tanh\left(\frac{s^{**}}{k_B}\right) \right\rangle^+. \quad \text{且有 } \langle \cdot \rangle^+ = \int_0^{+\infty} ds^{**} \int_{-t}^{+\infty} dt, p^+(s^{**}, t). \end{aligned}$$

使用综合算符的性质，我们有： $\langle s^{**} \rangle = \langle s^{**} \cdot \tanh\left(\frac{s^{**}}{k_B}\right) \rangle^+$.

$$\text{利用 Schwartz 不等式，有：} \langle JT \rangle^2 = \left(\langle J \cdot \tanh\left(\frac{s^{**}}{k_B}\right) \rangle^+ \right)^2 \leq \langle J \rangle^+ \langle \tanh^2\left(\frac{s^{**}}{k_B}\right) \rangle^+, \quad \text{且有 } \langle \tanh^2 x \rangle \leq \langle \tanh x \rangle^2 = \tanh(x)$$

$$\text{从而有 } \langle J \rangle^2 = \langle JT \rangle^2 \geq \langle J \rangle^2 - \langle T \rangle^2 \cdot \langle \tanh^2\left(\frac{s^{**}}{k_B}\right) \rangle^+ \geq \langle J \rangle^2 - \langle T \rangle^2 \tanh^2\left(\frac{s^{**}}{k_B}\right)^+ = \langle T^2 \rangle \left(1 - \tanh^2\left(\frac{s^{**}}{k_B}\right)\right)$$

从而有所指不等式成立： $\frac{\langle J \rangle^2}{\langle T^2 \rangle} \geq \frac{2}{\exp(s^{**}/k_B) - 1}$ 这里加上了与平衡态中给出的温度关系。注意到，当 $s^{**} \rightarrow 0$ 时， $\tanh^2(x) \rightarrow 1$ ，所以研究了平衡时的情况，有：

$$\frac{\langle J \rangle^2}{\langle T^2 \rangle} \geq \frac{2k_B}{s^{**}}, \quad T \ll k_B/s^{**}$$

这样就证明了最开始的推导过程是正确的。比如，考虑 $J(t)$ 为多少 current 的线性组合： $J(t) = \lambda_1 J_1(t) + \lambda_2 J_2(t)$ ， $J_1(t) = \exp(-\beta E_1 t)$ ， $J_2(t) = \exp(-\beta E_2 t)$ ， $E_1 > E_2$ ， $\lambda_1 > \lambda_2$ ， $\lambda_1 \lambda_2 < 0$ ， $\lambda_1 + \lambda_2 = 1$ ， $\lambda_1 \lambda_2 (C_{\text{ap}} - \lambda_1 \lambda_2 C_{\text{fp}}) > 0$ ， $\lambda_1 \lambda_2 (C_{\text{ap}} - \lambda_1 \lambda_2 C_{\text{fp}}) < 0$ ， $\lambda_1 \lambda_2 (C_{\text{ap}} - \lambda_1 \lambda_2 C_{\text{fp}}) = 0$ 。

$$\Rightarrow \langle \lambda_1 \lambda_2 J_1(t) + \lambda_1 \lambda_2 J_2(t) \rangle = \langle \lambda_1 \lambda_2 J_1(t) \rangle + \langle \lambda_1 \lambda_2 J_2(t) \rangle \geq \frac{1}{2} \langle \lambda_1 \lambda_2 J_1(t) \rangle + \langle \lambda_1 \lambda_2 J_2(t) \rangle \quad \text{根据线性组合的性质} \quad \lambda_1 = \frac{1}{2} (C_{\text{ap}} - C_{\text{fp}}) \quad \text{从而有：} \quad \lambda_1 \lambda_2 (C_{\text{ap}} - \lambda_1 \lambda_2 C_{\text{fp}}) \geq 0$$

$$\text{从而有：} \lambda_1 \lambda_2 (C_{\text{ap}} - \lambda_1 \lambda_2 C_{\text{fp}}) \geq 0$$

$$\lambda_1 \lambda_2 = \frac{1}{2} \lambda_1 \lambda_2 (C_{\text{ap}} - C_{\text{fp}}) \cdot \langle J_1(t) \rangle \langle J_2(t) \rangle$$

$$= \frac{1}{2} \lambda_1 \lambda_2 (E_1 - \langle E_1 \rangle) \langle E_2 \rangle \langle J_1(t) \rangle$$

$$= \frac{1}{2} \lambda_1 \lambda_2 (C_{\text{ap}} - \langle E_1 \rangle) \langle J_1(t) \rangle$$

$$= \frac{1}{2} \lambda_1 \lambda_2 (C_{\text{ap}} - \langle E_1 \rangle) \langle J_1(t) \rangle$$

$$\begin{aligned} \lambda_1 \lambda_2 &= \frac{1}{2} \lambda_1 \lambda_2 (C_{\text{ap}} - \lambda_1 \lambda_2 C_{\text{fp}}) \\ &= \frac{1}{2} \lambda_1 \lambda_2 (C_{\text{ap}} - \lambda_1 \lambda_2 C_{\text{fp}}) \langle J_1(t) \rangle \langle J_2(t) \rangle \\ &= \left(\frac{1}{2} \lambda_1 \lambda_2 (C_{\text{ap}} - \lambda_1 \lambda_2 C_{\text{fp}}) \right)^2 \end{aligned}$$

$$\Rightarrow \text{从上式可知有 } \frac{1}{2} \lambda_1 \lambda_2 (C_{\text{ap}} - \lambda_1 \lambda_2 C_{\text{fp}}) \geq 0 \quad \text{或者} \quad \lambda_1 \lambda_2 (C_{\text{ap}} - \lambda_1 \lambda_2 C_{\text{fp}}) \leq 0$$

对于时间相关的量，取 $T_{\alpha}^{tot} = \lim_{T \rightarrow \infty} T_{\alpha}$, $s^2 = [S_{\alpha\beta}] = \lim_{T \rightarrow \infty} C_{\alpha\beta}/T$. 同时有 $\mathbb{E}[T_{\alpha}^{tot}(G_{\alpha\beta})] = \frac{s^{tot}}{\alpha\beta}$.

我们继续引入一个参数 Γ 表示 Current 的 rate function 和 T_{α}^{tot} 之间的 bound [2]: $T_{\alpha}^{tot} \leq \frac{(1-\Gamma)^{-1}}{\alpha\beta} s^{tot}$. 且 $\int_{\alpha\beta}^{tot} = \frac{(1-\Gamma)^{-1}}{\alpha\beta} s^{tot}$. 且 $\left\{ \begin{array}{l} \bar{T}_{\alpha}^{tot} = k_{\alpha} p_{\alpha}^{tot} - k_{\beta} \times p_{\beta}^{tot} \\ \bar{s}_{\alpha\beta}^{tot} = 2k_{\alpha} \bar{T}_{\alpha}^{tot} \sinh(\frac{k_{\alpha} \bar{T}_{\alpha}^{tot}}{T}) \end{array} \right.$ $\frac{\partial \bar{s}_{\alpha\beta}^{tot}}{\partial \alpha} = \frac{C_{\alpha\beta} \bar{T}_{\alpha}^{tot}}{T}$

在两个式子中： $\mathbb{E}_{\alpha\beta}[\int_{\alpha\beta}^{tot}] = \int_{\alpha\beta}^{tot}, \bar{s}_{\alpha\beta}^{tot} = (\int_{\alpha\beta}^{tot})$. 你可以在平均位置附近， Γ 和 $(\int_{\alpha\beta}^{tot})$ 之间有其线性关系。

$$\text{LRB}(\int_{\alpha\beta}^{tot}) = \frac{\mathbb{E}_{\alpha\beta}[(\int_{\alpha\beta}^{tot})^2] - \bar{s}_{\alpha\beta}^{tot} \bar{s}_{\alpha\beta}^{tot}}{\mathbb{E}_{\alpha\beta}[\int_{\alpha\beta}^{tot}]} = \frac{\mathbb{E}_{\alpha\beta}[(1-\Gamma)^{-2}] - \bar{s}_{\alpha\beta}^{tot} \bar{s}_{\alpha\beta}^{tot}}{\mathbb{E}_{\alpha\beta}[\int_{\alpha\beta}^{tot}]} = \frac{\mathbb{E}_{\alpha\beta}[(1-\Gamma)^{-2}] - \frac{\bar{s}_{\alpha\beta}^{tot}}{\alpha\beta} \mathbb{E}_{\alpha\beta}[\int_{\alpha\beta}^{tot}]}{\mathbb{E}_{\alpha\beta}[\int_{\alpha\beta}^{tot}]} = \frac{\mathbb{E}_{\alpha\beta}[(1-\Gamma)^{-2}] - \bar{s}_{\alpha\beta}^{tot} \frac{\bar{T}_{\alpha}^{tot}}{\alpha\beta}}{\mathbb{E}_{\alpha\beta}[\int_{\alpha\beta}^{tot}]} \quad \text{所以我们可以利用这个简单的公式来对 \(\Gamma\) 的上界进行估计。}$$

由于 $\int_{\alpha\beta}^{tot}$ 只是近似值，还可以得到另一个不等式，设 $j = \mathbb{E}_{\alpha\beta}[\int_{\alpha\beta}^{tot}]$, \bar{T}_{α}^{tot} 和 $\bar{s}_{\alpha\beta}^{tot}$ 相等。我们有 $\int_{\alpha\beta}^{tot} \leq \mathbb{E}_{\alpha\beta}[\int_{\alpha\beta}^{tot}] = \frac{(1-\Gamma)^{-2}}{\alpha\beta} \bar{s}_{\alpha\beta}^{tot}$.

对于 Γ 的性质，显然有 $\mathbb{E}[\int_{\alpha\beta}^{tot}] \leq \mathbb{E}[\ln(\int_{\alpha\beta}^{tot})] = \frac{(\int_{\alpha\beta}^{tot} - \bar{s}_{\alpha\beta}^{tot})}{\alpha\beta \bar{s}_{\alpha\beta}^{tot}}$

+ 注意在前面，我们通过 $p_{\alpha\beta} = p_{\alpha} + q_{\beta} - p_{\alpha}q_{\beta}$ ，即 $p_{\alpha\beta} = \mathbb{E}[\int_{\alpha\beta}^{tot}]$ ，证明了逆平衡情形下 Γ 为正数。

Application of Uncertainty Relations.

在这个不确定性的框架下，行走速度 $V = \langle \dot{x} \rangle$ ，意味着行走的加速度为 f 。从而该获得的熵率为 $Ts^{tot} = \ln(\text{chem}) - fV$ ， chem 是分子浓度和化学势的比值。这和 ATP 的消耗率（或与 ATP 不消耗率）的平均有关，因此这个 Γ (Current)。 $Tn = \langle \dot{n} \rangle$, $\Delta \ln(\text{chem}) = \Delta \ln(n)$ 。定义行走的熵率为 $\eta = \frac{fV}{\ln(\text{chem})} = \frac{fV}{\Delta \ln(n)} = \frac{fV}{Ts^{tot}}$ 。

利用 ATP 消耗率增加的不确定性关系 $\frac{\bar{\eta}^2}{(\langle \dot{n} \rangle)^2} \geq \frac{2k_B}{Ts^{tot}}$ $\Rightarrow Ts^{tot} \geq 2k_B \cdot (\langle \dot{n} \rangle)^2 / \bar{\eta}^2$.

$$\Rightarrow \eta_s \leq \frac{fV}{fV + 2k_B \cdot (\langle \dot{n} \rangle)^2 / \bar{\eta}^2} = \frac{1}{1 + 2k_B \cdot (\langle \dot{n} \rangle)^2 / (\bar{\eta}^2 fV)} \quad \text{且 } \bar{\eta}^{tot} \geq 0 \Rightarrow \Delta \bar{\eta}^{tot} \geq fV^2 \Rightarrow \langle \dot{n} \rangle^2 = fV^2 / \Delta \bar{\eta}^{tot} \quad \text{从而进一步放缩}$$

$$\eta_s \leq \frac{1}{1 + 2k_B fV / (\bar{\eta}^2 \Delta \bar{\eta}^{tot})} \quad \hookrightarrow \text{不确定性关系的放大因子，只作用于行走 Current 上。}$$

类似的处理可用于应用其他模型，例如前面提到的 Kinesin Model.

First Passage Time.

现在我们考虑有限的行走 Current，首次穿越某一个阈值的时间 T_{fp} ($T_{fp} > 0$)。我们知道 $\ln(n)/T_{fp}$ 这个强度差，并且定义 $t_{fp} = T_{fp}/(k_B T)$ ，下面我们要证明 $t_{fp} \geq \frac{s^{tot}}{\Delta \bar{\eta}^{tot}}$ 一个不等式关系。 $\frac{\partial t_{fp}}{\partial \eta} \geq \frac{2k_B}{s^{tot}}$.

给定 Current Γ 大小， $P(T, \Gamma) = \exp(-T, \Gamma / \eta)$ 。现在我们用这个大偏差“反过采”，我们设 η 为正向下的，即下游是大偏差，反方向是小偏差。所以开始时 T_{fp} 也应该是大偏差，但没有影响：

$$P(T_{fp}, T_{fp}) \approx \begin{cases} \exp(-T_{fp}, \Gamma + T_{fp}/T_{fp}), & \text{if } T_{fp} > 0 \\ \exp(T_{fp}, \Gamma - (-T_{fp}/T_{fp})), & \text{if } T_{fp} \leq 0. \end{cases}$$

这个值并非常数，这说明出这个 rate function 和刚才的 $p(J_{thr}, T_{fp})$ 有些矛盾。
 $p(J_{thr}, T_{fp}) = \exp[-T_{fp} \cdot I \cdot (J_{thr}/T_{fp})]$ 没有，这两项四向有微弱的差别，第一个比第二个大，所以 T_{fp} 变为负的时候，
 $\{ p(T_{fp}, J_{thr}) = \exp[-J_{thr}^2 / (T_{fp}/J_{thr})]$ 而第三个比 T_{fp} 大时，由于 J_{thr} 的极差，但没有 J_{thr} 变小，这样保证可以
 $\Rightarrow I_+ (T_{fp}/J_{thr}) \cdot J_{thr} = T_{fp} \cdot I(J_{thr}/T_{fp}) \Rightarrow I_{+}^{(1)} (+_{fp}) = +_{fp}^{-2} (1/_{fp})$ 。这个是不对的， T_{fp} 和 J_{thr} 都应该是正确的。因此，我们通过将 rate function 算出来，
 同时我们通过上面的 scaled CDF。

$$\left\{ \begin{array}{l} q^{(1)}(q) = \lim_{t \rightarrow \infty} \frac{1}{t} \ln \exp(qt), \\ q^{(2)}(q) = \lim_{|t| \rightarrow \infty} \frac{1}{|t|} \ln \langle \exp(qt) \rangle. \end{array} \right.$$

它们之间有关系：

$$q^{(2)}(q) = -q^{(1)}(q)。其中士代表 q 的两个分支，下面进行证明。$$

$$q^{(1)}(q) = q \int^{\infty}_0 -I(q^*) \cdot dI = q.$$

接下来的证明，原处使用了非常迷惑的表达： t_{fp}^* "corresponds to" $1/j^*$ 。虽然这所东西是靠 $I'(t_{fp}) = 0$
 确定的，但和 2.9 我们得到的 $I'(t_{fp}) = t_{fp}^2 (1 + 1/t_{fp})$ 。 $t_{fp}^* = 1/j^*$ 这当然也是不成立的，但会找不到合适的表达式。

$$\left\{ \begin{array}{l} q^{(1)}(q) = q + t_{fp}^2 - I(t_{fp}^2), \quad I'(t_{fp}^2) = q. \\ \text{作为补充后面给出了 } I^{-1}. \end{array} \right.$$

不能这样，让我们从 $t_{fp}^* \leftrightarrow 1/j^*$ ，并继续接下来的证明。订正：

$$q^{(1)}(q) = -(q + t_{fp}^2 - I(t_{fp}^2)) j^* - 2(j^*)^2 = -q + \frac{1}{t_{fp}^2} I(t_{fp}^2) - 2(\frac{1}{t_{fp}^2}) = -q。从而可以完成证明。而这个证明也告诉我们 $q^{(1)}(q)$ 在哪个方向的导数与 $q^{(2)}(q)$ 在哪个方向的导数联系起来。$$

通过上面 scaled CDF 的 $I(t_{fp}) = 1$ ，我们立刻有： $|q(j)| = \frac{1}{2t_{fp}}$ 。 $\tilde{G}_j^2 = |j| \tilde{G}_{+}^2 = \frac{6t_{fp}}{K_{fp}^2}$ 。

对于一些特定的 Current，(特别有趣！)，由于滑移平衡条件的引入，其 SGF 对称性，这使得 t_{fp} 对应的 SGF 对称性： $q^{(1)}(t_{fp}) = q^{(1)}(-t_{fp}) = \frac{1}{t_{fp}}$ 。
 2.9 对于任意 Current 的 rate function 值的符号的讨论。 $I_{+}(t_{fp}) = 2 \ln \exp(t_{fp}) = \frac{(t - t_{fp})^2}{4t_{fp}} = \frac{1}{4t_{fp}} \tilde{G}_{+}^2$

Fully Reversible Processes.

在 2.9 的推导中，我们通常有所谓“微观可逆”/Microscopic Reversibility 的概念。即在 $x \rightarrow x'$ 的路径分析的时候， $x \rightarrow x'$ 的路径同时被分析，即带一些限制并不容易假设，
 单向互换。反向-1 例子：有一对滑移阻塞，最初时从右到左，L-L 动态运动。L-L 滑移板，右基 $-t_{fp}(1-t_{fp})$ ，L-L 滑移板突然固定，从而粒子从右到左，L-L 滑移。

在这样的过程中，单向和反向的 I ，从而 $\langle \exp(-W/k_B T) \rangle = 1$ ，单位时间的 $\Delta t = -T \Delta S = -k_B T / \ln 4S / L_0$ 。从而 $\langle \exp(W/k_B T) \rangle = 1$ 逆反。

为了简化这一结论，我们应看什么时候我们打破了微观可逆假设。即一共有 n 个是被阻塞的，若 $P_{\text{out}} > 0$ ，若微可逆不成成立，则有 $P_{\text{out}}(x) > 0$ 的路径， $P_{\text{in}}(x) = 0$ 。

上面倒数 2.9 中的路径对应于（直向路径中）反向的“关门”时间后，粒子仍位于 L-L 之间的那些路径。对这样们的反向路径，它们对应的正向路径不能到达，从而我们得
 到正向路径 $\pi(x)$ 的反向物： $P_{\text{in}}(x) = \int P_{\text{out}}(y) dy$ ，如果 π 是可逆的。 π 为前有： $\langle \exp(-S_{\text{out}}(y)/k_B T) \rangle = \int P_{\text{out}}(y) \exp(-S_{\text{out}}(y)/k_B T) = \int P_{\text{in}}(x) \exp(-S_{\text{in}}(x)/k_B T) = P_{\text{in}}(x) = \text{prev}$ 。
 所以有 π 路径在反向路径中出现的关系

在前几讲的例子中， $\langle \exp(-S_{\text{out}}(y)/k_B T) \rangle_F = -1/c_F = \text{prev}$ 。对于我们的例子是完全正确的。

再一个例子，考虑一个上的 L。对于 $x < L$ ， $L \rightarrow (x+1)$ 和 $(x+1) \rightarrow x$ 都成立。 $L \rightarrow (x+1)$ 但 $x \rightarrow L$ 不行。我们称 L 为 fully / absolutely irreversible 但是所有事件的因果关系都相同的时候。且 $x \in I(1,0)$ 都不产生熵。只有 $L \rightarrow L$ 产生。这和对于 T_{iso} 和 T_{ad} 事件有区别。不可逆的过程只会产生膨胀过程： $\int_{t=t_0}^{t=T} dt \cdot p_T \cdot \exp(-S(T) \cdot \partial_T) / \partial_T = p_{\text{iso}}(C_T)$ 。

上一个例子的表达式是部分确定。 $\frac{dp_{\text{prev}}}{dt} = p_{\text{prev}}(C_t) - p_{\text{iso}}(C_t)$

另一种更简单的例子是有 upshock 的时候。若 x 是路经的事件，则 $p_{\text{prev}}(C_t)$ 会变大， $p_{\text{iso}}(C_t)$ 会变小，从而导致不可逆性。

Optimal Protocols

设一个不带耗散 manipulation protocol。{lambda} 为常数。{lambda}(t) 与 {lambda}(0) 确定。热力学量为 $w_{\text{diss}} = w - \text{inf}$ 最小的 manipulation。（即：使不同的增加内能等于同种耗散的方法）

考虑不带耗散的热力学量此时有： $W = \frac{dF}{dt} \cdot T_{\text{iso}}(C_t)$ 。 $W_{\text{diss}}(t)$ 可以被写成： $W_{\text{diss}}(t) = \frac{dF}{dt} \cdot g_{\text{dp}}(\lambda(t)) \cdot \frac{d\lambda}{dt} \cdot \frac{d\beta}{dt}$ 。即称为“改善率因子”。是物理半卫星。

若 $\lambda_{\text{max}} = \frac{\partial S_{\text{ext}}(C_t)}{\partial \alpha}$ 则 $g_{\text{dp}}(t) = \frac{1}{k_B T} \int_0^t dt' \cdot C_{\text{dp}}(t')$ 。其中 $C_{\text{dp}}(t) = \langle (x_{\text{dp}}(t) - \langle x_{\text{dp}}(0) \rangle^{eq}) \cdot (x_{\text{dp}}(0) - \langle x_{\text{dp}}(t) \rangle^{eq}) \rangle^{eq}$ 。每一个 $\langle \dots \rangle^{eq}$ 表示着在平衡线上对 α 和其倒数。

$$g_{\text{dp}}(0) = \frac{1}{k_B T} \int_0^{T_{\text{iso}}} dt \cdot C_{\text{dp}}(t; \lambda) \quad \text{下证证明:}$$

$$W = \frac{dF}{dt} + W_{\text{diss}}(t) \Rightarrow W_{\text{diss}}(t) = W - \frac{dF}{dt} \quad F = k_B T_{\text{iso}} \cdot Z \quad \frac{dF}{dt} = -k_B T \cdot \frac{1}{Z} \cdot \frac{d(Z \cdot \exp(-E_t/k_B T))}{d\alpha} \cdot \frac{d\alpha}{dt} \cdot \frac{dZ}{d\alpha} = \frac{1}{Z} \exp(-E_t/k_B T) \frac{d\alpha}{dt} \cdot \frac{dZ}{d\alpha}$$

$$= \frac{1}{Z} \cdot \frac{d\alpha}{dt} \langle (x_{\text{dp}}(t), \lambda(t)) \rangle_{\lambda(t)} - \frac{1}{Z} \frac{d\alpha}{dt} \langle (x_{\text{dp}}(0), \lambda(0)) \rangle^{eq}$$

根据前面对 Linear Response Theory 的分析，在恒定的温度的情况下，可对固定 α 对平衡态的偏移写出：

$$\langle x_{\text{dp}}(t; \lambda(0)) \rangle_{\lambda(t)} - \langle x_{\text{dp}}(\lambda(0)) \rangle^{eq} = \frac{1}{Z} \int_{-\infty}^t [C_{\text{dp}}(t-t') \cdot (\lambda_p(t') - \lambda^{eq})] \cdot (\lambda_p(t') - \lambda^{eq}) dt' \quad \text{其中 } \lim_{t \rightarrow -\infty} \lambda(t) = \lambda^{eq} \quad \lambda(t) > \lambda^{eq} \quad \text{或} \quad \lambda(t) < \lambda^{eq}$$

利用 K 与相关函数之间的关系。 $K_{\text{dp}}(t; \lambda) = -\frac{d\alpha}{dt}$ 。且 $C_{\text{dp}}(t; \lambda) =$

$$\text{LHS} = \frac{1}{Z} \int_{-\infty}^t -\frac{\partial \alpha}{k_B T} \frac{d}{dt} C_{\text{dp}}(t'; \lambda(t')) \cdot (\lambda_p(t') - \lambda^{eq}) dt' \quad \text{忽略上部。} \\ = \frac{1}{Z} \int_{-\infty}^t -\frac{1}{k_B T} \frac{d(\alpha(t') C_{\text{dp}}(t'; \lambda(t')) (\lambda_p(t') - \lambda^{eq}))}{dt'} dt' + \frac{1}{Z} \int_{-\infty}^t \frac{d\lambda(t')}{dt'} (C_{\text{dp}}(t'; \lambda(t')) - \frac{1}{Z} \int_{-\infty}^t \frac{d\alpha(t')}{dt'} (C_{\text{dp}}(t'; \lambda(t')) - \lambda^{eq})) dt' \quad \text{由上部} \frac{d\alpha(t')}{dt'} \text{忽略} \Rightarrow \frac{d\alpha(t')}{dt'} = 0$$

$$\text{LHS} \approx \frac{1}{Z} \frac{1}{k_B T} \frac{d\alpha}{dt} \int_{-\infty}^t dt' \cdot C_{\text{dp}}(t-t'; \lambda(t)) \cdot \frac{d\lambda(t')}{dt'} \quad \text{忽略上部。} \quad t = t-t'.$$

$$= \frac{1}{k_B T} \frac{d\alpha}{dt} \cdot \frac{d\lambda}{dt} \int_0^{T_{\text{iso}}} dt \cdot C_{\text{dp}}(t; \lambda(t)) \frac{d\lambda(t)}{dt} \Big|_{t=0}.$$

注意到相关函数 $C_{\text{dp}}(t; \lambda(0))$ 通过插值多项式， $C_{\text{dp}}(t; \lambda(0)) = \frac{1}{2} \lambda(0) + \frac{1}{2} \lambda(t)$ 。从上我们得到 Taylor 展开。 $\frac{d\lambda(t)}{dt} \Big|_{t=0} = \frac{d\lambda}{dt} - \frac{1}{2} \frac{d^2 \lambda}{dt^2} + O(t^2)$

在一定的条件下，可以将相关函数写成 $\lambda(t)$ 。如果 $\lambda(t)$ 对 t 全部是线性的，即有 $W_{\text{diss}}(t) = \frac{1}{Z} \frac{d\alpha}{dt} g_{\text{dp}}(\lambda(t)) \frac{d\lambda}{dt}$ 。

对于一些特定例子，例如在高度和位置可调的角滑轮的布朗运动。 $\frac{dx}{dt} = -\mu_p \cdot k \cdot (x - l) + g(t)$, $\langle x(t) \rangle = 0$, $\langle x(t)x(t') \rangle = 2\mu_p k T \cdot \delta(t-t')$.

对于一个不可见的，随时间变化的， $\frac{dx(t)}{dt} = -k(x-l)$, $\frac{dx(t)}{dt} = \frac{1}{2} k(x-l)^2$,
对应的方程问题。 $\Rightarrow dx/dt = \text{Const.}$ $\frac{dx(t)}{dt} = \text{Const.}$ $\begin{pmatrix} l+k\delta t & \exp(-\mu_p k \delta t) \\ 0 & 0 \end{pmatrix} \Rightarrow g(t,t) = \begin{pmatrix} 1/\mu_p & 0 \\ 0 & \mu_p T / (\mu_p k^2) \end{pmatrix}$.

从而获得运动的强度。Optimal Protocol 的意义是递归的。 $\{x_m\}$ 所成的序列内的强度为 $I[x] = \int_0^T dt \sqrt{\frac{1}{\mu_p} \frac{\partial g_{op}(x_m)}{\partial x} d\log \frac{dx}{dt}}$.

利用 C-S 不等式可得 $W_{op} \leq T^2 L^2$.

Martingales.

看一眼随机行走。对于 $t=t_1, t_2, \dots, t_n$ 在一个 t_1, t_2, t_3, \dots 的序列对随机进行估计， $\langle x(t_1) | x(t_1), x(t_2), x(t_3), \dots \rangle = x(t_1)$ 。这样该随机过程取， $x(t_1)$ 。在 $x(t_1)$ 的基础上。

对于 $x(t_1)$ 的前导估计是 $x(t_1)$ ，或者说取最后一个“带有漂移”的随机。若某一直线从 t_1 到 t_2 通过的点是 $x(t_1) + \zeta$ 中已有的信息和假设是正确的，则该直线的斜率。

有一重要定理称为 Doob 预测定理。它声称 $\langle x(t+\tau) | x(t) \rangle = x(t)$ 。要使用它，应至少满足以下条件。

• 偏移有限。• 与时间无关。 $\langle t(t) \rangle < +\infty$ 。且偏移界。 $|x(t+\tau) - x(t)| \leq c$ • 均值有限。 $|x(t)| \leq c + t(t)$

不满足以上条件的例子包括一个绝对随机行走的随机过程。

随机的主要应用有：对于处于稳定的系统。 $\exp(-S^{tot}(t)/k_B)$ 是软丁型，最起码的性。我的大帝界。 $\langle \exp(-S^{tot}(t)/k_B) | \exp(-S^{tot}(t)/k_B) \rangle$

$\exp(S^{tot}(t)/k_B) = \frac{P_x}{P_E} = \frac{P_{x1} P_{x2} \dots}{P_{x1} P_{x2} \dots P_{xn}}$ 用 x_i 表示 $t \rightarrow t+i$ 间的轨迹。同理将 t_1, t_2, \dots 间的轨迹 纳并用同样方法表示。 $S^{tot}(t) = S_1 + S_{2,3, \dots}$.

$$\begin{aligned} \text{从即计算: } \langle \exp(-S^{tot}(t)/k_B) | \exp(-S^{tot}(t)/k_B) \rangle &= \frac{\int dx_1 dx_2 \dots P_x \exp(-S^{tot}(t)/k_B) \delta(S^{tot}(t) - S)}{\int dx_1 \int dx_2 \dots P_x \delta(S^{tot}(t) - S)} \\ &= \frac{\int dx_1 \dots P_{x1} P_{x2} \dots \exp(-S_1/k_B) \exp(-S_{2,3,\dots}/k_B) \delta(S^{tot}(t) - S)}{\int dx_1 \dots P_{x1} P_{x2} \dots P_{x1} \delta(S^{tot}(t) - S)} \\ &= \frac{\int P_{x1} \dots P_{x1} |_{x_1=S_1} \dots \overbrace{\exp(-S_{2,3,\dots}/k_B)}^{\text{exp}(-S_{2,3,\dots}/k_B)}, \dots \cdot \exp(-S_1/k_B)}{\int P_{x1} \dots P_{x1}} = \frac{\int P_{x1} \dots P_{x1} \delta(S^{tot}(t) - S_1) \delta^{x_1(x_1, x_1)}}{\int P_{x1} \dots P_{x1} \delta(S^{tot}(t) - S_1)}. \end{aligned}$$

$$\text{令 } \lambda = \frac{P_{x1}|_{x_1} P_{x1}}{P_{x1}|_{x_1} \dots P_{x1}} = \exp\left(\frac{S^{tot}(t)}{k_B}\right) \text{ 有:}$$

$$\begin{aligned} \langle \exp(-S^{tot}(t)/k_B) | \exp(-S^{tot}(t)/k_B) \rangle &= \exp(-S_1/k_B) \cdot \frac{\int dx_2 \dots P_{x2}|_{x_1} \dots P_{x1}|_{x_1}}{\int P_{x1} \dots P_{x1}} \frac{P_{x1}|_{x_1} P_{x1}}{\int P_{x1} \dots P_{x1}} = \exp(-S^{tot}(t)/k_B) \int P_{x1} \dots P_{x1} \frac{P_{x1}|_{x_1}}{\int P_{x1} \dots P_{x1}} \\ &= \exp(-S_1/k_B) \cdot \int P_{x2} \dots P_{x1} \frac{P_{x1}|_{x_1}}{P_{x1}|_{x_1}} \end{aligned}$$

需要先知道两个概率，一个不被反射回去的反射率。反射到反射点的反射强度等于 $p(x_0)$ 。 这些强度的反射率和正向率相等，所反射的高反射率。

由反射率递推可得证明，对于角度 (x_1, \dots, x_n) ，有 $P_S = \frac{1}{n!} \prod_{i=1}^n p(x_i) W_{x_1 x_2 \dots x_n} = p(x_0)$ 。 对于至多有一个反射，反射率不成立推导。

从而上面我们得到反射点 x_0 的反射率 $\int dx_2 \dots dx_n p_{x_0} P_S |_{x_0} \cdot \frac{p_{x_0}}{p_{x_1}} = \int dx_2 \dots dx_n p_{x_0} \cdot \frac{c}{c} = \frac{1}{n!} p_{x_1} \cdot \frac{p_{x_1}}{p_{x_1}} = \frac{1}{n!} p_{x_1}$ ，从而得证。

由 Dode 经典证明， $\langle \exp(-S^{tot}/k_B) \rangle_{T^{stop}} = 1$ 。

证明 1. 若将待证设为 $\theta = 0 > 2$ ，首次出现 $\exp(-S^{tot}/k_B) > 0$ 的时间，是反射时间的总反射数的。但有 $0 < \langle \exp(-S^{tot}/k_B) \rangle_{T^{stop}} \leq 1$ ，即由 Dode's Theorem 的第 13 条。对于那些没有碰到 C 的轨迹，在 $t \rightarrow \infty$ 时有 $\exp(-S^{tot}/k_B) \rightarrow 0$ 。

即若我们取 $\theta = (\exp(-S^{tot}/k_B) - 1)$ ，其中 c, α, β 是力学量上的初值，显然，其初速度 v_0 有 $v_0 = 1/c$ 。故 v_0 变化的幅度正比于 $S = -k_B \ln \exp(-S^{tot}/k_B)$ 。

该式 $v_0 S^{tot} \leq S$ for some finite $+ \infty = \exp(S/k_B)$ 。这正是 S 的一个下界。从而有 $v_0 (\inf S^{tot} \geq S) = \frac{1}{k_B} \exp(S/k_B)$ 。

从而我们从时间上高产生于 S 的下界与 S 相对应的。对于无碰撞的轨迹，由于它可以一直走“直线”，因此 $\exp(S/k_B)$ 是一个上界。

→ Random time.

对于无碰撞的辐射产生，我们用一种技术，称为 random time transformation，具体而言，我们有一个随机过程和反射事件产生一个随机的反射时间。

此时，需要引入 $d\tau$ ，从而获得对时间的写法，而不是 dt 。从而时间写成。

$$\frac{d}{dt} \epsilon(x,t) = \frac{\partial}{\partial t} \epsilon(x,t) + \frac{\partial}{\partial x} \epsilon(x,t) \cdot \frac{dx}{dt} + D \cdot \frac{\partial^2}{\partial x^2} \epsilon(x,t),$$

$$\text{且有 } \frac{d}{dt} w(x,t) = \frac{\partial}{\partial t} \epsilon(x,t) + \text{fix}(x) \cdot \frac{dx}{dt} + D \cdot \frac{\partial^2}{\partial x^2} \int^x dx'.$$

\int^x dx' = \text{fix}(x) \int^x dx'.

$$\lim_{t \rightarrow \infty} \epsilon(x+dx,t) - \epsilon(x,t).$$

带有 δ 项吗？

$$\text{从反射率反射} \rightarrow \text{反射率} = \frac{1}{n!} W(x+dx) - \frac{1}{n!} \epsilon(x+dx) = f(x,t) \cdot \frac{dx}{dt} + D \cdot \frac{\partial}{\partial x} f(x,t).$$

$$\text{反射的幅度} = \frac{1}{n!} p(x+dx) = -k_B \left[\frac{1}{p(x,t)} \cdot \frac{\partial}{\partial t} p(x,t) + \frac{1}{p(x,t)} \cdot \frac{\partial}{\partial x} p(x,t) \cdot dx/dt + \frac{D}{p(x,t)} \cdot \frac{\partial^2}{\partial x^2} p(x,t) \right] = \dots$$

通过反向应用 $d\tau$ 公式进行计算，有：

$$\frac{d}{dt} S^{tot, random} = \tau(t) + C = k_B \left[-\frac{1}{p(x,t)} \cdot \frac{\partial}{\partial t} p(x,t) + \frac{T^2(x,t)}{D p^2(x,t)} \right] \rightarrow \frac{T^2(x,t)}{D p(x,t)} \cdot g(t). \quad \text{反射率} \text{ 产生速度 } v_S(x,t) = \frac{T^2(x,t)}{D p^2(x,t)}.$$

$$\text{且有 } \frac{dS^{tot}}{dt} = k_B T^2 \cdot \frac{\partial}{\partial t} \ln p(x,t) + v_S(x,t) + \sqrt{2v_S(x,t) \cdot \frac{\partial}{\partial t} v_S(x,t)}. \quad \text{反射率} \text{ 产生} \frac{d}{dt} \exp(-S^{tot}/k_B) = -\exp(-S^{tot}/k_B) \cdot \sqrt{2v_S(x,t) \cdot \frac{\partial}{\partial t} v_S(x,t)}.$$

从而辐射和吸收的速率（粒子数变化率）相等。在这些我们引入的新的“随机时间” $d\tau$ 和 dt 有 $d\tau \approx v_S(x,t) dt$ 。代入 T^2 。

$\frac{d}{dt} S^{tot} = k_B + k_B T^2 \cdot \frac{\partial}{\partial t} \ln p(x,t) + v_S(x,t) \cdot \frac{d}{dt} \exp(-S^{tot}/k_B) = k_B + k_B T^2 \cdot \frac{\partial}{\partial t} \ln p(x,t) - v_S(x,t) \cdot \frac{d}{dt} \exp(-S^{tot}/k_B)$ 。这就是我们所说的“随机时间”的反射率。所有的都是不变的，这也就是说为了由 Dode 经典得出的结论运用了这个方法。

Population Genetics.

下面我们讨论单性和群体的进化的某些类似。一个核心概念是，单二指的突变率对应于“群体适应度”分母。

我们将群体的个体上影响其繁殖率的特征称为繁殖率，最后一个 $N(t+1) \rightarrow 1$ 的种群进行繁殖率繁殖率是一分为二的。

在单一叶群体有 $N(t)$ 个个体。对于每个个体，我们用其繁殖率 p_x 和祖先辈数（称为“谱系”）来研究它。

在实际中，种群数目实际上都相对较小，一种简单的方法是忽略自相关性，分裂一次，追踪一个具体的个体。我们关注 $N(t)$ 时细胞的祖先辈数，它的范围从 $N(t) \rightarrow N(t)$ 平衡。然后我们追踪单个 clone。追踪该种群中一个个体的所有后代，跟踪这些后代的适应度。（在后代的群体中，我们追踪每条谱系的个体数）。

• 编码群体：从种群中选一个随机个体。

• 四倍群体：从种群中选择一个随机个体。

设 p_{px} 为某群体某样本来繁殖为 x 的个体的谱系，△ 谱系指的是根—叶的一条路径，即分支。 $n_{px} + f_x$ 时到群体繁殖率为 x 的个体数，即：

对四倍群体 $p_{net} = n_{px} / N(t)$ 。这是显然的。对于偏时，以前的祖先是一样的。即 $w_i \cdot \frac{1}{N(t)}$ 的概率集中繁殖了 p_{px} 的叶子。 $w_i p_{px}^{chr} = \frac{2^i p}{N(t)} \cdot n_{px}$ 是 p_{px} 的谱系。

整个种群的谱系 $\Lambda = \ln(p_{net}) / N(t)$ 。两个群体到某样本来谱系的频率相等。 $p_{px}^{net} = \exp(\Lambda) \cdot p_{px}^{chr}$ 。 $\Lambda = \frac{1}{N(t)}$ 是谱系产生。

在这里， p_{px} 和 p_{px}^{chr} 是平行的正向、反向概率，而 $\Lambda = \ln(p_{px} / p_{px}^{chr})$ 是谱系产生。

下面我们将计算某一类型的适应度，它可以类似于利用有某一类型的个体的期望后代数目。然而这可能相当困难。我们做如下定义： $P_x^{rep} = \sum_i p_{px}^{net} ; P_x^{chr} = \sum_i p_{px}^{chr}$ 。定义单类型的 fitness landscape / 适应度景观。 $h_x = \frac{1}{N(t)} \ln \frac{N(t+1) \cdot P_x^{net}}{N(t) \cdot P_x^{chr}} = \Lambda + \frac{1}{N(t)} \ln \frac{P_x^{net}}{P_x^{chr}} \Rightarrow P_x^{net} = \exp(\Lambda + h_x) \cdot P_x^{chr}$ 。

利用 $p_{px} = P_x^{chr} / P_x^{net}$ 和 $p_{px}^{net} = N(t) / N(t+1) \cdot 2^i \cdot P_x^{net}$ 可以得到 h_x 的互相关性。 $h_x = \frac{1}{N(t)} \ln \frac{1}{2} + 2^i \cdot P_x^{net}$ 。

下面考虑所谓表型转换 / phenotype switching 改变。它描述了选择压力下群体个体表型变化的过程。这个表型从 $x \rightarrow x'$ 的切换率为 $k_{xx'}$ 。在切换时，一个个体具有 $\exp(d_{xx'})$ 表型转换 ($d_{xx'} < 0$)。定义一个谱系的表型路径 $\vec{x} = ((x_0, t_0), (x_1, t_1), \dots, (x_n, t_n), t_f)$ 。设置表型为 x 时，个体的频率 $n_{xx}^{\vec{x}}$ 。 $n_{xx}^{\vec{x}}$ 表示表型 x 的谱系的个体。

其期望后代总数为： $N_{\vec{x}} = \exp(r_{xx'} + t_f - t_0)$ 。 $\prod_{i=0}^{n-1} (\exp(r_{xx'} + t_{i+1} - t_i) + d_{xx'} n_{xx}^{\vec{x}(i)}) = \exp \left[\sum_i r_{xx'}(i) + \sum_i d_{xx'} n_{xx}^{\vec{x}(i)} \right]$ 。

$t_{\vec{x}}(i)$ 是在 x 上的驻留时间而 $n_{xx}^{\vec{x}(i)}$ 为 $x \rightarrow x'$ 的切换频率。

虽然一个种群表型路径的总数可用前述至方程路径的概率密度写出，从而计算到该种群数目 $N^{tot}(t_f) = \int p_{\vec{x}} \cdot N_{\vec{x}} \cdot P_{\vec{x}} \cdot N^{tot}(t_0)$ 。

增长率 $\Lambda = \lim_{T \rightarrow \infty} \frac{1}{T} \ln(N(t)) = \lim_{T \rightarrow \infty} \frac{1}{T} \ln \left(\exp \left[\sum_i r_{xx'}(i) + \sum_i d_{xx'} n_{xx}^{\vec{x}(i)} \right] \right)$ 它且是 $r_{xx'}(i)$ 和 $n_{xx}^{\vec{x}(i)}$ 的 scaled CDF 上的累积 rate function。 $r_{xx'}(i)$

有： $\Lambda = \inf_{f_{xx'}} \left[\sum_i r_{xx'}(i) + \sum_i d_{xx'} n_{xx}^{\vec{x}(i)} f_{xx'}(i) - 2 \ln(f_{xx'}(i)) \right]$ 。极值的 $f_{xx'}$ 有其他用处。